

# Regressão Logística com Dois Atributos e Gradiente Descendente Manual

## 1 Dados

$i$	$x_{1i}$	$x_{2i}$	$y_i$
1	0	0	0
2	1	0	0
3	0	1	1

Modelo com intercepto:

$$\hat{y}_i = \sigma(z_i), \quad z_i = w_0 + w_1 x_{1i} + w_2 x_{2i}, \quad \sigma(z) = \frac{1}{1 + e^{-z}}.$$

## 2 Função-custo e gradientes

$$J(\mathbf{w}) = -\frac{1}{m} \sum_{i=1}^m \left[ y_i \ln \hat{y}_i + (1 - y_i) \ln(1 - \hat{y}_i) \right], \quad m = 3.$$

$$\frac{\partial J}{\partial w_0} = \frac{1}{m} \sum_{i=1}^m (\hat{y}_i - y_i), \quad \frac{\partial J}{\partial w_1} = \frac{1}{m} \sum_{i=1}^m (\hat{y}_i - y_i) x_{1i}, \quad \frac{\partial J}{\partial w_2} = \frac{1}{m} \sum_{i=1}^m (\hat{y}_i - y_i) x_{2i}.$$

## 3 Hiperparâmetros

- Pesos iniciais:  $w_0^{(0)} = w_1^{(0)} = w_2^{(0)} = 0$
- Taxa de aprendizagem:  $\alpha = 0.5$

## 4 Iterações do gradiente descendente

Iteração 0  $\rightarrow$  1

$$\hat{y}_i^{(0)} = \sigma(0) = 0.5 \quad \forall i$$

$$g_{w_0}^{(0)} = \frac{1}{3} (0.5 + 0.5 - 0.5) = 0.1667,$$

$$g_{w_1}^{(0)} = \frac{1}{3} (0.5 \cdot 0 + 0.5 \cdot 1 + (-0.5) \cdot 0) = 0.1667,$$

$$g_{w_2}^{(0)} = \frac{1}{3} (0.5 \cdot 0 + 0.5 \cdot 0 + (-0.5) \cdot 1) = -0.1667.$$

$$\begin{aligned} w_0^{(1)} &= 0 - 0.5 \cdot 0.1667 = -0.0833, \\ w_1^{(1)} &= 0 - 0.5 \cdot 0.1667 = -0.0833, \\ w_2^{(1)} &= 0 - 0.5 \cdot (-0.1667) = 0.0833. \end{aligned}$$

### Iteração 1 $\rightarrow$ 2

$$\begin{aligned} z^{(1)} &= [-0.0833, -0.1666, 0.0000], \\ \hat{y}^{(1)} &= \sigma(z^{(1)}) \approx [0.4792, 0.4585, 0.5000]. \\ g_{w_0}^{(1)} &= \frac{1}{3}(0.4792 + 0.4585 - 0.5) = 0.1459, \\ g_{w_1}^{(1)} &= \frac{1}{3}(0 + 0.4585 + 0) = 0.1528, \\ g_{w_2}^{(1)} &= \frac{1}{3}(0 + 0 - 0.5) = -0.1667. \end{aligned}$$

$$\begin{aligned} w_0^{(2)} &= -0.0833 - 0.5 \cdot 0.1459 = -0.1563, \\ w_1^{(2)} &= -0.0833 - 0.5 \cdot 0.1528 = -0.1597, \\ w_2^{(2)} &= 0.0833 - 0.5 \cdot (-0.1667) = 0.1667. \end{aligned}$$

### Iteração 2 $\rightarrow$ 3

$$\begin{aligned} z^{(2)} &= [-0.1563, -0.3160, 0.0104], \\ \hat{y}^{(2)} &\approx [0.4610, 0.4217, 0.5026]. \\ g_{w_0}^{(2)} &= \frac{1}{3}(0.4610 + 0.4217 - 0.4974) = 0.1284, \\ g_{w_1}^{(2)} &= \frac{1}{3}(0 + 0.4217 + 0) = 0.1406, \\ g_{w_2}^{(2)} &= \frac{1}{3}(0 + 0 - 0.4974) = -0.1658. \end{aligned}$$

$$\begin{aligned} w_0^{(3)} &= -0.1563 - 0.5 \cdot 0.1284 = -0.2205, \\ w_1^{(3)} &= -0.1597 - 0.5 \cdot 0.1406 = -0.2299, \\ w_2^{(3)} &= 0.1667 - 0.5 \cdot (-0.1658) = 0.2496. \end{aligned}$$

## 5 Observações

- O peso  $w_1$  torna-se negativo enquanto  $w_2$  cresce positivamente, coerente com o fato de que  $x_2 = 1$  está associado a  $y = 1$  e  $x_1 = 1$  está associado a  $y = 0$ .
- Mais iterações continuarão a ajustar os pesos até que a variação em  $J$  se torne pequena.
- O procedimento geral com mais atributos ou amostras é idêntico: calculam-se gradientes, aplicam-se as atualizações, repete-se.