Desafios da da Computação

SBC

2 de abril de 2026

Sumário

1 O papel da Inteligência Artificial nos Grandes Desafios da Computação no Brasil 2025–2035 **2**
1.1 Como enfrentar os desafios da IA nos Grandes Desafios da Computação no Brasil 2025–2035? 3

2 Quais são os principais desafios de dados para o avanço da Inteligência Artificial? **3**
2.1 Quais abordagens a literatura propõe para enfrentar os desafios de dados no avanço da Inteligência Artificial? . 4

3 O que é Inteligência Artificial responsável e quais são os desafios para sua operacionalização? **5**
3.1 Como enfrentar os desafios da operacionalização da Inteligência Artificial responsável? 6

4 Como a heterogeneidade de dados impacta sistemas de Inteligência Artificial e quais são os principais desafios associados? **7**
4.1 Quais abordagens permitem enfrentar os desafios impostos pela heterogeneidade de dados em sistemas de Inteligência Artificial? 7

5 Quais são os principais desafios de segurança em sistemas de Inteligência Artificial? **8**
5.1 Como enfrentar os desafios de segurança em sistemas de Inteligência Artificial? 9

6 Quais são os principais desafios na avaliação de sistemas de Inteligência Artificial? **9**
6.1 Como enfrentar os desafios na avaliação de sistemas de Inteligência Artificial? 10

7 Quais são os principais desafios atuais em cibersegurança? **11**
7.1 Como enfrentar os principais desafios atuais em cibersegurança? 11

8 Como a Inteligência Artificial e a cibersegurança se relacionam? **12**
8.1 Como enfrentar os desafios na interseção entre Inteligência Artificial e cibersegurança? 13

9 Qual é o papel dos fatores humanos na cibersegurança e quais desafios estão associados? **13**
9.1 Como enfrentar os desafios associados aos fatores humanos na cibersegurança? 14

10 Quais são os impactos da computação quântica na computação moderna? **15**
10.1 Como enfrentar os impactos da computação quântica na computação moderna? 15

11 Qual é o impacto da computação quântica na cibersegurança? **16**
11.1 Como enfrentar o impacto da computação quântica na cibersegurança? 17

12 Qual é o papel da computação na sociedade e quais desafios estão associados? **17**
12.1 Como enfrentar os desafios associados ao papel da computação na sociedade? 18

13 Quais são os principais desafios de escalabilidade e infraestrutura na computação moderna? **19**
13.1 Como enfrentar os desafios de escalabilidade e infraestrutura na computação moderna? 19

14 Quais são os desafios ambientais da computação moderna? **20**
14.1 Como enfrentar os desafios ambientais da computação moderna? 21

15 Como definir uma agenda de pesquisa relevante em computação atualmente? **21**
15.1 Como construir e sustentar uma agenda de pesquisa relevante em computação no Brasil? 22

16 Quais são os desafios do acesso universal e significativo à Internet no Brasil? **23**

16.1 Como enfrentar os desafios do acesso universal e significativo à Internet no Brasil? 24

17 Quais são os desafios da computação sustentável e seu impacto socioambiental? 24

17.1 Como enfrentar os desafios da computação sustentável? 25

18 Quais são os desafios para a formação de recursos humanos em computação no Brasil? 26

18.1 Como enfrentar os desafios para a formação de recursos humanos em computação no Brasil? 27

1. O papel da Inteligência Artificial nos Grandes Desafios da Computação no Brasil 2025–2035

A IA não é mais uma subárea da computação com fronteiras bem definidas. Ela atravessa os seis Grandes Desafios da SBC para 2025–2035 de formas concretas e distintas, o que justifica seu tratamento como primeiro e mais transversal dos desafios: sem IA responsável, bem estruturada em dados e infraestrutura, os demais desafios ficam comprometidos na base.

O potencial concreto é bem documentado. Em saúde, sistemas treinados sobre exames e históricos clínicos identificam padrões que escapam à percepção humana, apoiando diagnósticos precoces. Na gestão pública, a análise de grandes volumes de dados muda o que é viável em formulação e avaliação de políticas. Na educação, permite personalização em escala. Em todos esses casos, o que opera é uma capacidade comum: transformar dados em previsão, classificação e recomendação — reunindo aprendizado de máquina, processamento de linguagem natural, visão computacional, agentes e robótica.

O problema é que esse avanço expôs gargalos estruturais que antes passavam despercebidos. Eles se organizam em quatro dimensões interdependentes — e entender como cada uma se conecta aos outros desafios é o que dá à pergunta sua resposta mais precisa.

A primeira dimensão é a dos dados. Não há IA confiável sem dados adequados, e na prática eles são incompletos, enviesados e espalhados entre fontes com distribuições distintas. Quando refletem desigualdades históricas — como ocorre em sistemas de alocação de recursos em saúde ou de avaliação de risco em justiça — o modelo aprende a reproduzi-las. Qualidade de dados é, antes de tudo, uma questão social. Esse problema conecta diretamente a IA ao desafio de ecossistemas computacionais éticos e inclusivos: dados produzidos em condições desiguais geram sistemas que perpetuam essa desigualdade, e nenhuma técnica de curadoria resolve isso sem mudanças nas condições institucionais que os produziram.

A segunda é algorítmica. Modelos fundacionais e redes profundas alcançaram desempenho impressionante em tarefas complexas, mas ao custo de se tornarem opacos. Em aplicações de alto impacto — decisões médicas, concessão de crédito, triagem judicial — não saber por que um modelo chegou a determinada conclusão deixa de ser um problema acadêmico e vira risco concreto para direitos individuais. Isso se conecta diretamente ao desafio de cibersegurança: modelos opacos são também modelos vulneráveis a ataques adversariais, manipulação de entrada e exploração de comportamentos inesperados fora da distribuição de treinamento.

A terceira é computacional e de infraestrutura. Treinar modelos de grande escala consome energia em quantidades que crescem mais rápido do que a capacidade de geração em países como o Brasil, e essa infraestrutura está concentrada em poucas organizações globais. A dependência não é só tecnológica — é também política. Esse eixo conecta a IA diretamente ao desafio de computação sustentável: o crescimento projetado do consumo energético de data centers, estimado para dobrar entre 2022 e 2026, é em grande parte impulsionado por cargas de treinamento e inferência de modelos de IA. E conecta-se também ao desafio de acesso universal à Internet, já que infraestrutura concentrada amplia a exclusão digital de regiões e países sem capacidade de processamento local.

A quarta, e provavelmente a mais difícil, é a da responsabilidade. Princípios como beneficência, não maleficência, justiça, autonomia e transparência são amplamente aceitos como guias para o desenvolvimento de IA, mas transformá-los em critérios operacionais de projeto e auditoria continua sendo um problema em aberto. A distância entre o que se declara e o que se implementa é grande — e fechá-la exige métricas, processos de validação, monitoramento contínuo e regulações que ainda estão sendo construídos. Esse desafio conecta a IA ao tema de ecossistemas éticos e inclusivos de forma direta: sem mecanismos concretos de governança, a IA responsável permanece como princípio e não como prática.

Há ainda a interseção com computação quântica, que importa por razões de segurança: algoritmos quânticos como o de Shor comprometem esquemas criptográficos sobre os quais sistemas de IA em produção frequentemente dependem para proteger dados e comunicações. E há a formação de recursos humanos, desafio transversal a todos os outros: o déficit estimado de profissionais especializados em cibersegurança no Brasil em 2024 estava entre 140 e 750 mil, e a escassez de profissionais capazes de desenvolver e aplicar IA de forma ética e técnica é igualmente crítica.

No contexto brasileiro, esses problemas têm uma dimensão extra que o documento da SBC trata como risco de soberania. Depender de modelos treinados em outros contextos linguísticos e culturais não é um detalhe técnico — é uma vulnerabilidade estrutural. Desenvolver IA que funcione para a realidade brasileira, com seus dados, suas línguas e suas desigualdades específicas, exige investimento próprio em formação, infraestrutura de dados representativos e pesquisa aplicada a problemas nacionais. Não há atalho nisso, e o documento é explícito nesse ponto.

A IA está no centro dos Grandes Desafios não porque é promissora, mas porque concentra e amplifica as tensões mais difíceis da computação contemporânea: entre desempenho e confiabilidade, entre escala e sustentabilidade, entre automação e responsabilidade, entre adotar o que o mundo desenvolveu e construir o que o Brasil precisa.

Cada um dos outros cinco desafios tem um componente de IA — e cada um deles, por sua vez, impõe condições que a IA sozinha não resolve.

1.1. Como enfrentar os desafios da IA nos Grandes Desafios da Computação no Brasil 2025–2035?

Enfrentar os desafios da IA nos Grandes Desafios da SBC exige reconhecer, de saída, que não existe uma frente única de atuação. As quatro dimensões identificadas — dados, algoritmos, infraestrutura e responsabilidade — têm naturezas distintas e exigem respostas distintas. O que as conecta é a necessidade de articulação: intervenções isoladas em uma dimensão tendem a ser insuficientes quando as outras permanecem intactas.

No plano dos dados, a resposta mais influente tem sido o movimento denominado *data-centric AI*, que propõe deslocar o esforço de desenvolvimento para práticas rigorosas de curadoria, documentação e qualidade dos dados, em vez de concentrá-lo exclusivamente no refinamento de modelos. Iniciativas como *datasheets for datasets* e *data cards* propõem esquemas padronizados que registram condições de coleta, composição e limitações de cada base, promovendo rastreabilidade e auditabilidade. Para o problema do viés estrutural, técnicas de *fairness-aware machine learning* buscam identificar e mitigar desequilíbrios antes, durante e após o treinamento — mas com um limite importante: quando o viés reflete desigualdades historicamente constituídas, intervenções puramente técnicas atuam sobre os sintomas sem alterar as condições que os produziram. Para dados distribuídos entre organizações sem possibilidade de centralização, o aprendizado federado oferece uma alternativa relevante, embora introduza novos desafios de heterogeneidade entre participantes e de robustez a ataques. E onde a abertura dos dados não é viável por razões de privacidade, técnicas como privacidade diferencial e computação multipartidária segura permitem extrair informações agregadas sem expor dados individuais.

No plano algorítmico, o foco tem sido o desenvolvimento de técnicas de explicabilidade e interpretabilidade que permitam auditar decisões de modelos opacos. Métodos como SHAP e LIME oferecem aproximações locais de comportamento de modelos complexos, mas cada um com limitações bem documentadas: não há consenso sobre o que conta como explicação adequada, e a escolha do método afeta diretamente o que se pode inferir. Para robustez adversarial, abordagens como treinamento adversarial e certificação formal buscam produzir modelos mais resistentes a perturbações de entrada, com aplicação especialmente relevante em contextos críticos como saúde e segurança. A transferência de aprendizado e a adaptação de domínio, por sua vez, reduzem a dependência de grandes volumes de dados rotulados em cada novo contexto, permitindo reaproveitar representações aprendidas em um domínio para situações com distribuições distintas.

No plano da infraestrutura e sustentabilidade, as respostas operam em múltiplas camadas. Do lado do hardware, o desenvolvimento de aceleradores especializados e arquiteturas mais eficientes busca reduzir o custo energético do treinamento e da inferência. Do lado do software, técnicas como quantização, destilação de modelos e poda reduzem a complexidade computacional sem perda proporcional de desempenho — tornando viável a execução de modelos em infraestruturas menores. Para o Brasil especificamente, o documento da SBC aponta a necessidade de construir infraestruturas nacionais de dados representativos e de ampliar a geração de energia por fontes renováveis para compensar o crescimento do consumo digital, reduzindo tanto a dependência tecnológica quanto o impacto ambiental.

No plano da responsabilidade, o desafio central é a operacionalização. Princípios como beneficência, justiça e transparência precisam ser traduzidos em métricas mensuráveis, processos de auditoria e mecanismos de responsabilização ao longo de todo o ciclo de vida dos sistemas. Do ponto de vista regulatório, marcos como o *AI Act* europeu e a LGPD estabelecem obrigações de transparência e proteção de dados, mas sua aplicação específica a sistemas de IA ainda carece de detalhamento, especialmente para decisões automatizadas de alto impacto. Isso reforça a necessidade de interdisciplinaridade: a operacionalização da IA responsável não é um problema que computeiros resolvem sozinhos — ela exige colaboração com juristas, cientistas sociais, especialistas em ética e representantes das populações afetadas.

Para o Brasil, há ainda uma frente de atuação que atravessa todas as outras: a formação de recursos humanos. O documento da SBC é explícito ao afirmar que é urgente formar e atrair profissionais capazes de desenvolver e aplicar IA de forma técnica e eticamente competente. Isso não se limita a graduações em computação — exige atualização curricular, formação continuada, programas de pós-graduação orientados a problemas nacionais e parcerias entre universidades e setor produtivo. Sem isso, qualquer avanço em dados, algoritmos ou regulação depende de capacidade humana que o país ainda não tem em escala suficiente.

O que a literatura mais recente tem enfatizado — e o que o documento da SBC reflete — é que essas frentes de atuação não funcionam de forma sequencial. Avanços técnicos sem governança produzem sistemas potentes e irresponsáveis. Regulação sem infraestrutura de dados adequada permanece letra morta. Infraestrutura sem formação de pessoas não se sustenta. A aposta mais promissora é a que integra essas dimensões simultaneamente, reconhecendo que os desafios da IA no Brasil são ao mesmo tempo técnicos, institucionais e políticos — e que enfrentá-los exige respostas da mesma natureza.

2. Quais são os principais desafios de dados para o avanço da Inteligência Artificial?

A Inteligência Artificial contemporânea é fortemente dependente de dados, a ponto de muitas de suas limitações atuais não decorrerem de insuficiências algorítmicas, mas de problemas associados à disponibilidade, qualidade, organização e uso dos dados. Identificado pela SBC como um dos eixos centrais do Grande Desafio de promoção da evolução responsável da IA para o período 2025–2035, esse tema articula ciência e engenharia de dados como perspectivas complementares no enfrentamento de questões estruturais que condicionam a confiabilidade e o impacto social dos sistemas de IA.

O primeiro grande desafio é a heterogeneidade dos dados. Em aplicações reais, os dados raramente são independentes e identicamente distribuídos, apresentando variações temporais, espaciais, institucionais e semânticas. Essa heterogeneidade se manifesta em diferenças de distribuição entre bases, mudanças ao longo do tempo e inconsistências de representação, comprometendo a robustez e a capacidade de generalização dos modelos. No contexto brasileiro, esse problema é agravado pela diversidade regional, pela fragmentação de sistemas de informação públicos e pela dependência de bases de dados produzidas em outros contextos culturais e institucionais.

Um segundo desafio fundamental é a qualidade dos dados, entendida como adequação ao uso. Dados podem ser incompletos, ruidosos, enviesados ou mal rotulados, e esses problemas impactam diretamente o desempenho e a confiabilidade dos sistemas de IA. Além disso, a crescente utilização de dados sintéticos e dados gerados por modelos introduz novos riscos, como amplificação de vieses e perda de controle sobre a veracidade das informações — uma preocupação especialmente relevante em aplicações de alto impacto social, como saúde, educação e justiça. *Um exemplo ilustrativo ocorre quando sistemas de alocação de recursos em saúde utilizam custo histórico de atendimento como indicador de necessidade médica: populações que historicamente tiveram menos acesso a serviços de saúde geram menos custos registrados, não por serem mais saudáveis, mas por terem sido sistematicamente subatendidas. O modelo aprende esse padrão e passa a direcionar recursos para quem já foi mais atendido, penalizando justamente os grupos mais vulneráveis. Esse exemplo evidencia que viés nos dados não é uma anomalia técnica isolada, mas uma consequência direta das condições sociais em que os dados foram produzidos — e que qualidade dos dados é, antes de tudo, uma questão social.*

Associado a isso está o desafio de proveniência e rastreabilidade. Em sistemas complexos, torna-se essencial saber a origem dos dados e os processos de coleta, transformação e uso a que foram submetidos. A ausência de mecanismos robustos de documentação compromete a auditabilidade, a reprodutibilidade e a confiança nos sistemas, especialmente em contextos críticos nos quais decisões automatizadas afetam direitos e oportunidades de indivíduos.

Outro desafio relevante é a integração de dados heterogêneos. Em muitas aplicações, o valor está na combinação de múltiplas fontes — estruturadas e não estruturadas, tabulares, textuais e visuais. Esse processo exige métodos capazes de lidar com diferentes representações e níveis de granularidade, sendo um problema ainda aberto em muitos contextos, especialmente em cenários multimodais e em aplicações que combinam dados de saúde, mobilidade e comportamento.

Há também desafios relacionados à disponibilidade e ao acesso aos dados. Em diversos domínios, dados relevantes estão distribuídos entre organizações e sujeitos a restrições legais, comerciais ou de privacidade, o que dificulta a construção de bases representativas e limita o treinamento de modelos mais generalizáveis. No Brasil, a dificuldade de acesso a dados públicos de qualidade e a ausência de infraestruturas nacionais de compartilhamento de dados constituem obstáculos concretos ao desenvolvimento de IA soberana e adaptada às realidades locais.

Além disso, a escala dos dados impõe desafios computacionais e metodológicos. O volume crescente exige infraestrutura adequada e algoritmos eficientes, mas também demanda estratégias de seleção e curadoria, já que mais dados não necessariamente implicam melhor desempenho — e podem, ao contrário, amplificar problemas de qualidade e viés quando não tratados adequadamente.

Por fim, emerge o desafio da governança de dados. À medida que sistemas de IA passam a influenciar decisões de alto impacto, torna-se necessário estabelecer políticas, métricas e processos que garantam uso ético, transparente e responsável dos dados. Isso inclui aspectos de privacidade e proteção de dados — dimensão regulada no Brasil pela LGPD —, equidade no acesso e nos benefícios gerados, mecanismos de responsabilização e auditoria, e a definição de critérios claros de proveniência e consentimento. A governança de dados é, nesse sentido, o elo entre os desafios técnicos e as exigências da IA responsável.

Do ponto de vista das recomendações, o documento da SBC aponta direções para diferentes setores. Para o setor público e as agências de fomento, destaca a necessidade de montar comitês multidisciplinares para avaliação de projetos envolvendo IA e dados, garantindo que aspectos técnicos e sociais sejam considerados conjuntamente. Para as universidades e o setor produtivo, recomenda o envolvimento de equipes interdisciplinares no estudo de problemas que envolvam grandes volumes de dados, reconhecendo que ciência e engenharia de dados se complementam no enfrentamento das questões de heterogeneidade, curadoria, proveniência e qualidade. Para todos os setores, enfatiza que IA deve ser tratada como subárea da Computação, de modo que questões relacionadas a dados sejam sempre resolvidas com a participação ativa de especialistas nos aspectos computacionais relevantes.

Em síntese, os desafios de dados para IA podem ser organizados em três dimensões complementares: técnica, que envolve heterogeneidade, integração e escala; epistêmica, relacionada à qualidade, proveniência e rastreabilidade; e institucional, que abrange acesso, governança e uso responsável. O avanço sustentável da IA depende, portanto, de uma agenda integrada em ciência e engenharia de dados, capaz de transformar dados brutos em ativos confiáveis, interpretáveis e adequados para sistemas robustos e socialmente responsáveis — condição indispensável para que o Brasil desenvolva soberania tecnológica real nesse domínio.

2.1. Quais abordagens a literatura propõe para enfrentar os desafios de dados no avanço da Inteligência Artificial?

O reconhecimento de que os principais gargalos da Inteligência Artificial contemporânea residem nos dados — e não apenas nos algoritmos — tem impulsionado, nas últimas décadas, o desenvolvimento de um conjunto articulado de abordagens técnicas, metodológicas e institucionais. Essas abordagens não devem ser entendidas como soluções isoladas para problemas pontuais, mas como respostas a dimensões estruturais que se entrecruzam: a dimensão técnica, relacionada à heterogeneidade, integração e escala; a dimensão epistêmica, que envolve qualidade, proveniência e rastreabilidade; e a dimensão institucional, que abrange acesso, governança e uso responsável dos dados.

No plano técnico, o enfrentamento da heterogeneidade motivou o desenvolvimento de abordagens como aprendizado por transferência e adaptação de domínio, que permitem reaproveitar conhecimento adquirido em um contexto para situações com distribuições distintas, reduzindo a dependência de grandes volumes de dados rotulados em cada novo domínio. Para lidar com mudanças ao longo do tempo, métodos de detecção e tratamento de *concept drift* buscam identificar quando a distribuição dos dados se altera de forma significativa, sinalizando a necessidade de retreinamento ou adaptação dos modelos. A integração de fontes heterogêneas, por sua vez, tem sido abordada pelo campo de aprendizado de representação, que busca construir espaços latentes comuns capazes de capturar estruturas compartilhadas entre diferentes modalidades — textuais, visuais, tabulares e temporais. Para o problema de acesso a dados distribuídos, o aprendizado federado emerge como uma alternativa relevante, ao permitir o treinamento de modelos sobre dados que permanecem nos dispositivos ou organizações de origem, sem necessidade de centralização. Embora promissor, esse paradigma introduz novos desafios de heterogeneidade entre participantes e de robustez a comportamentos adversariais, evidenciando que soluções técnicas raramente eliminam os problemas subjacentes — apenas os deslocam para novos níveis de complexidade.

No plano epistêmico, a resposta mais influente tem sido o movimento denominado *data-centric AI*, articulado a partir da constatação de que melhorias sistemáticas na qualidade dos dados frequentemente produzem ganhos de desempenho superiores aos obtidos pelo refinamento dos modelos. Essa perspectiva propõe deslocar o esforço de desenvolvimento para práticas rigorosas de curadoria, limpeza, balanceamento e documentação dos dados. Nesse contexto, iniciativas como *datasheets for datasets* e *data cards* propõem esquemas padronizados de documentação que registram as condições de coleta, composição, limitações e usos pretendidos de cada base de dados, promovendo rastreabilidade e auditabilidade. Para o problema específico do viés, técnicas de *fairness-aware machine learning* buscam identificar e mitigar desequilíbrios antes, durante e após o treinamento, por meio de restrições algorítmicas, reponderação de amostras e métricas de equidade desagregadas por grupo. No entanto, é importante reconhecer os limites dessas abordagens: quando o viés é estrutural — isto é, quando reflete desigualdades sociais historicamente constituídas, como no exemplo da alocação de recursos em saúde — intervenções puramente técnicas tendem a ser insuficientes, pois atuam sobre os sintomas sem alterar as condições que os produziram. Isso reforça a necessidade de articular respostas técnicas com mudanças institucionais e políticas.

No plano institucional, as respostas emergentes combinam instrumentos regulatórios, infraestruturais e de governança. Do ponto de vista regulatório, marcos como o *AI Act* europeu e, no Brasil, a LGPD estabelecem obrigações de transparência, responsabilização e proteção de dados que condicionam o desenvolvimento e o uso de sistemas de IA. No entanto, a aplicação específica dessas regulações a sistemas de IA ainda carece de detalhamento, especialmente no que diz respeito a decisões automatizadas de alto impacto. Do ponto de vista infraestrutural, iniciativas de dados abertos governamentais e propostas de infraestruturas nacionais de dados buscam ampliar o acesso a bases representativas, reduzindo a dependência de conjuntos de dados produzidos em outros contextos. Para situações em que a abertura dos dados não é possível por razões de privacidade, técnicas como privacidade diferencial e computação multipartidária segura oferecem mecanismos que permitem extrair informações agregadas sem expor dados individuais, equilibrando utilidade analítica e proteção de direitos.

O que une essas abordagens — e o que a literatura mais recente tem enfatizado — é a compreensão de que os desafios de dados em IA não têm solução exclusivamente técnica. Cada avanço metodológico revela novas camadas de complexidade, e cada intervenção isolada tende a ser insuficiente quando não acompanhada de mudanças nas práticas institucionais e nas condições sociais que moldam a produção dos dados. Nesse sentido, a agenda de pesquisa mais promissora é aquela que integra as três dimensões — técnica, epistêmica e institucional — reconhecendo que a qualidade dos dados é, antes de tudo, uma questão social, e que sistemas de IA confiáveis e equitativos dependem de ecossistemas de dados igualmente confiáveis e equitativos.

3. O que é Inteligência Artificial responsável e quais são os desafios para sua operacionalização?

Inteligência Artificial responsável é o conjunto de práticas, princípios e mecanismos que buscam garantir que sistemas de IA sejam desenvolvidos e operados de forma segura, justa, transparente e alinhada a valores humanos e institucionais — ao longo de todo o ciclo de vida, da concepção ao monitoramento em produção. A definição é razoavelmente consensual. O problema está em sair dela.

Os princípios mais citados são beneficência, não maleficência, justiça, autonomia e transparência. Beneficência refere-se à obrigação de que sistemas de IA promovam ativamente o bem-estar individual e coletivo; não maleficência, sua contraparte, exige que danos sejam prevenidos ou minimizados — inclusive danos indiretos e não intencionais. Justiça diz respeito à equidade no tratamento de indivíduos e grupos, incluindo não discriminação e distribuição equitativa de benefícios e riscos. Autonomia envolve a preservação da capacidade de decisão humana, garantindo que sistemas automatizados não substituam o julgamento humano em contextos nos quais ele é irrenunciável. Transparência abrange explicabilidade, auditabilidade e responsabilização — a possibilidade de entender, examinar e contestar as decisões de um sistema.

O que a literatura tem mostrado com crescente clareza é que esses princípios não são apenas abstratos — eles são frequentemente incompatíveis entre si. Maximizar desempenho preditivo e garantir equidade entre grupos raramente andam juntos: modelos mais precisos em média tendem a ser mais imprecisos para grupos sub-representados nos dados. Transparência e robustez adversarial também criam tensão: explicar como um modelo funciona pode revelar exatamente as brechas que um adversário precisa para manipulá-lo. Autonomia humana e automação em escala são, por definição, grandezas inversamente proporcionais. Escolher entre esses princípios não é uma falha de implementação — é uma decisão normativa que os sistemas precisam tomar, e que raramente é tornada explícita.

O principal desafio é exatamente esse: operacionalizar. Princípios abstratos precisam virar métricas mensuráveis, processos de auditoria e critérios concretos de projeto. Garantir justiça em um modelo de IA exige, primeiro, definir

formalmente o que significa equidade naquele contexto específico — e existem dezenas de definições matemáticas de equidade, muitas delas mutuamente exclusivas. Transparência pode significar coisas muito diferentes dependendo do tipo de modelo, do público que precisa da explicação e do domínio de aplicação: a explicação adequada para um médico que usa um sistema de apoio diagnóstico é completamente diferente da explicação adequada para o paciente cujo tratamento foi influenciado por esse sistema. Não há resposta técnica única para nenhuma dessas perguntas.

A governança ao longo do ciclo de vida é um segundo eixo de dificuldade. Sistemas em produção mudam — os dados mudam, o contexto muda, o comportamento do modelo deriva. Monitoramento contínuo, detecção de mudanças de distribuição e responsabilização por degradação de desempenho ou surgimento de vieses são problemas técnicos e institucionais simultaneamente. Definir quem é responsável quando um sistema aprende continuamente e produz uma decisão discriminatória dois anos após sua implantação é uma questão em aberto tanto do ponto de vista jurídico quanto organizacional.

Dados e robustez entram aqui como condições de viabilidade, não como tópicos paralelos. Vieses nos dados são reproduzidos e frequentemente amplificados pelos modelos — e quando esses vieses são estruturais, nenhuma técnica de curadoria resolve o problema sem mudanças nas condições que o produziram. Robustez a ataques adversariais é outra dimensão: sistemas de IA podem ser manipulados por perturbações nos dados de entrada que são imperceptíveis para humanos, o que compromete sua confiabilidade justamente nas situações em que ela mais importa.

A operacionalização da IA responsável não é um problema que a computação resolve sozinha. Ela exige colaboração entre computação, direito, ciências sociais e ética — e exige profissionais capazes de transitar entre essas linguagens. Essa interdisciplinaridade não é opcional: muitos dos problemas centrais são normativos e contextuais, e não têm resposta técnica. Desenvolvê-la exige reformas curriculares e uma cultura de formação que ainda não está consolidada.

O que muda de paradigma na IA responsável não é a intenção — é o critério. Sucesso deixa de ser medido apenas por acurácia, throughput ou custo computacional, e passa a incluir conformidade ética, auditabilidade e impacto social mensurável. Isso é mais difícil do que parece, porque exige que as organizações desenvolvam métricas para coisas que historicamente não mediam — e que aceitem que otimizar essas métricas pode significar abrir mão de desempenho em outras.

3.1. Como enfrentar os desafios da operacionalização da Inteligência Artificial responsável?

Enfrentar os desafios da IA responsável exige aceitar, de partida, que não há solução técnica para a maioria deles. O problema central — transformar princípios normativos em mecanismos concretos de projeto, avaliação e governança — é irredutivelmente interdisciplinar. As respostas disponíveis operam em três planos que precisam avançar juntos: o técnico, o institucional e o formativo.

No plano técnico, o foco tem sido desenvolver ferramentas que tornem os princípios mensuráveis. Para transparência, métodos como SHAP e LIME oferecem aproximações locais do comportamento de modelos complexos, permitindo identificar quais variáveis mais influenciaram uma decisão específica. Não são explicações perfeitas — têm limitações bem documentadas e podem ser instáveis — mas são os instrumentos disponíveis para auditar modelos que de outra forma seriam completamente opacos. Para justiça, técnicas de *fairness-aware machine learning* buscam identificar e mitigar desequilíbrios antes, durante e após o treinamento, por meio de restrições algorítmicas, reponderação de amostras e métricas de equidade desagregadas por grupo. O limite dessas abordagens é conhecido: quando o viés é estrutural, intervenções puramente técnicas atuam sobre os sintomas sem alterar as condições que os produziram. Para robustez, treinamento adversarial e certificação formal produzem modelos mais resistentes a perturbações de entrada, com aplicação especialmente relevante em contextos críticos. E para governança do ciclo de vida, ferramentas de monitoramento contínuo buscam detectar mudanças de distribuição, degradação de desempenho e surgimento de vieses em sistemas em produção — reconhecendo que um modelo validado no momento da implantação pode tornar-se problemático meses depois.

No plano institucional, as respostas combinam regulação, infraestrutura e processos organizacionais. Do ponto de vista regulatório, marcos como o *AI Act* europeu e a LGPD estabelecem obrigações de transparência, responsabilização e proteção de dados que condicionam o desenvolvimento de sistemas de IA. Sua limitação atual é que a aplicação a decisões automatizadas de alto impacto ainda carece de detalhamento — os princípios estão na lei, mas os critérios operacionais de cumprimento ainda estão sendo construídos. Do ponto de vista organizacional, a resposta mais promissora tem sido a criação de processos estruturados de avaliação de risco antes da implantação, auditorias periódicas durante a operação e mecanismos formais de responsabilização quando sistemas produzem danos. Isso exige que as organizações definam quem responde pelo comportamento de um sistema ao longo do tempo — uma questão que ainda não tem resposta jurídica consolidada em nenhum ordenamento.

No plano formativo, a lacuna é dupla. De um lado, faltam profissionais de computação com formação em ética, direito e ciências sociais suficiente para incorporar essas perspectivas no desenvolvimento de sistemas. De outro, faltam juristas, filósofos e cientistas sociais com familiaridade técnica suficiente para participar de forma substantiva das decisões de projeto. Resolver isso não é questão de adicionar uma disciplina de ética ao currículo de computação — exige redesenhar como a formação interdisciplinar é estruturada e avaliada, o que é um problema institucional de longo prazo.

O que atravessa esses três planos é uma constatação incômoda: os trade-offs entre princípios não desaparecem com melhores ferramentas ou regulações mais detalhadas. Eles precisam ser tornados explícitos, debatidos e decididos — e essa decisão tem natureza política, não técnica. A contribuição mais honesta que a computação pode dar à IA responsável é tornar esses trade-offs visíveis e auditáveis, em vez de ocultá-los em escolhas de implementação que ninguém examina.

4. Como a heterogeneidade de dados impacta sistemas de Inteligência Artificial e quais são os principais desafios associados?

Dados independentes e identicamente distribuídos são uma convenção matemática útil, não uma descrição do mundo real. Na prática, dados variam ao longo do tempo, entre regiões, entre instituições e entre modalidades — e essa heterogeneidade é a regra, não a exceção. O problema não é novo, mas ganhou escala com a disseminação de sistemas de IA em contextos cada vez mais diversos e com a crescente dependência de dados coletados em condições que o desenvolvedor não controla.

O impacto mais direto é sobre a capacidade de generalização. Modelos treinados em uma distribuição específica capturam padrões que podem não se sustentar em outras. Quando os dados de treinamento e os dados de produção divergem — seja por mudança temporal, por diferença regional ou por variação institucional — o modelo degrada. Essa degradação raramente é uniforme: tende a ser mais severa para grupos sub-representados nos dados de treinamento, o que transforma um problema técnico de generalização em um problema de equidade. Um modelo de triagem médica treinado predominantemente com dados de hospitais urbanos do Sul do país pode funcionar bem em média e mal exatamente para as populações que mais precisariam de apoio diagnóstico.

A heterogeneidade temporal tem nome próprio: *concept drift*. Distribuições mudam — comportamentos de usuários mudam, padrões de doenças mudam, mercados mudam — e modelos estáticos ficam para trás. O desafio não é apenas detectar quando isso acontece, mas decidir o que fazer: retreinar do zero, adaptar incrementalmente ou manter o modelo antigo com monitoramento mais apertado. Cada opção tem custos e riscos diferentes, e não há resposta universal.

A integração de fontes heterogêneas é outro eixo de dificuldade. Combinar dados estruturados e não estruturados, tabulares e textuais, de alta e baixa granularidade, exige métodos capazes de alinhar representações sem destruir informação relevante. Em contextos multimodais — saúde, por exemplo, onde coexistem imagens, exames laboratoriais, histórico clínico e anotações médicas em texto livre — esse problema ainda está longe de resolvido. Aprendizado de representação e modelos fundacionais multimodais avançaram significativamente, mas a transferência para domínios específicos com dados escassos continua sendo um gargalo.

No aprendizado federado, a heterogeneidade assume uma forma adicional: os dados não apenas variam entre clientes como permanecem onde estão, inacessíveis para centralização. Isso cria instabilidade no processo de otimização, dificulta convergência e pode degradar o desempenho global quando as distribuições locais são muito distintas. Métodos como FedProx e agregação ponderada por qualidade local tentam mitigar esses efeitos, mas introduzem novos hiperparâmetros e premissas que precisam ser validados caso a caso.

Há ainda o problema de avaliação. Métricas agregadas — acurácia global, F1 médio — podem mascarar diferenças de desempenho entre subgrupos que são exatamente as diferenças que importam. Um modelo com 90% de acurácia geral pode ter 70% de acurácia para um grupo específico, e essa discrepância só aparece quando a avaliação é desagregada. Isso não é um detalhe metodológico — é o que separa sistemas que funcionam para todos dos que funcionam bem em média e mal para os mais vulneráveis.

O que torna a heterogeneidade de dados especialmente difícil é que ela não tem solução única. Adaptação de domínio, aprendizado por transferência, aprendizado multitarefa e métodos robustos a mudanças de distribuição são respostas parciais a manifestações específicas do problema. Nenhuma delas elimina a necessidade de compreender a estrutura e a origem dos dados antes de modelar — e essa compreensão exige tanto competência técnica quanto conhecimento do domínio de aplicação. É um problema que a computação não resolve sozinha.

4.1. Quais abordagens permitem enfrentar os desafios impostos pela heterogeneidade de dados em sistemas de Inteligência Artificial?

Não existe abordagem única para heterogeneidade de dados — o que existe é um conjunto de respostas parciais, cada uma calibrada para uma manifestação específica do problema. A escolha entre elas depende do tipo de heterogeneidade, do domínio de aplicação e dos recursos disponíveis. O risco mais comum não é desconhecer essas abordagens, mas aplicá-las sem entender seus pressupostos e seus limites.

Para heterogeneidade entre domínios, as respostas mais consolidadas vêm do campo de adaptação de domínio e aprendizado por transferência. A ideia central é reaproveitar representações aprendidas em um contexto com dados abundantes para situações com distribuições distintas e dados escassos, reduzindo a dependência de grandes volumes de dados rotulados em cada novo domínio. Modelos fundacionais pré-treinados em larga escala e depois ajustados para tarefas específicas (*fine-tuning*) são a expressão mais visível dessa abordagem hoje — com resultados expressivos em linguagem natural, visão computacional e, mais recentemente, em domínios multimodais. O limite é que a transferência funciona melhor quando os domínios de origem e destino compartilham estrutura suficiente. Quando a distância entre distribuições é grande demais, o modelo transferido pode ser pior do que um modelo simples treinado do zero com poucos dados locais.

Para heterogeneidade temporal — *concept drift* —, as respostas envolvem monitoramento contínuo e retreinamento adaptativo. Métodos de detecção de drift buscam identificar quando a distribuição dos dados de produção se afasta significativamente da distribuição de treinamento, sinalizando a necessidade de intervenção. A dificuldade está em distinguir drift real de ruído estatístico, e em decidir quando retreinar — cedo demais desperdiça recursos, tarde demais deixa o modelo degradado em produção. Janelas deslizantes, pesos decrescentes para dados antigos e ensembles adaptativos são estratégias disponíveis, cada uma com trade-offs de custo computacional e estabilidade.

Para dados distribuídos sem possibilidade de centralização, o aprendizado federado é a resposta mais desenvolvida. Modelos são treinados localmente em cada cliente e apenas atualizações agregadas — não os dados brutos — são

compartilhadas. Isso preserva privacidade e viabiliza treinamento em contextos onde regulação ou competição impedem o compartilhamento de dados. O problema é que heterogeneidade entre clientes (*non-IID*) desestabiliza a otimização: a média simples de gradientes locais converge mal quando as distribuições locais são muito distintas. Variantes como FedProx, que penaliza desvios excessivos dos modelos locais em relação ao modelo global, e estratégias de agrupamento de clientes por similaridade de distribuição, atenuam esse problema sem eliminá-lo. Há ainda a questão de robustez a clientes maliciosos ou com dados corrompidos, que pode comprometer o modelo global de formas difíceis de detectar.

Para integração de fontes heterogêneas, o aprendizado de representação multimodal busca construir espaços latentes comuns capazes de capturar estruturas compartilhadas entre modalidades distintas. Em saúde, por exemplo, isso significa aprender representações que integrem imagens, séries temporais de exames e texto clínico de forma que cada modalidade complemente as outras em vez de competir por dominância no modelo. É uma área em rápido avanço, mas com desafios práticos significativos: dados faltantes por modalidade são a regra, não a exceção, e modelos multimodais tendem a ser frágeis quando uma modalidade ausente é justamente aquela mais informativa.

Para o problema de avaliação, a resposta é metodológica antes de ser técnica: desagregar métricas por subgrupo, domínio e contexto de aplicação, em vez de reportar apenas desempenho médio. Isso exige que os dados de avaliação sejam representativos dos subgrupos que importam — o que remete ao problema de curadoria e documentação discutido no contexto de *data-centric AI*. Sem avaliação desagregada, é impossível saber se um modelo que funciona bem em média está falhando sistematicamente para grupos específicos.

O que atravessa todas essas abordagens é uma premissa comum: compreender a estrutura e a origem dos dados antes de modelar é condição de viabilidade, não etapa opcional. Nenhum método de adaptação de domínio substitui o conhecimento de por que os domínios diferem. Nenhum detector de drift funciona bem sem uma hipótese sobre que tipo de mudança é esperada. A heterogeneidade de dados é, antes de tudo, um problema de conhecimento do domínio — e a computação entra para tornar esse conhecimento operacionalizável em escala.

5. Quais são os principais desafios de segurança em sistemas de Inteligência Artificial?

Segurança em sistemas de IA é um problema distinto de segurança em software tradicional — e a distinção importa. Em sistemas convencionais, o comportamento é explicitamente programado: vulnerabilidades existem porque código tem bugs ou porque arquiteturas têm falhas de projeto. Em sistemas de IA, o comportamento é aprendido a partir de dados. Isso significa que a superfície de ataque inclui não apenas o código e a infraestrutura, mas os próprios dados e o processo de aprendizado — e que vulnerabilidades podem ser introduzidas de formas que não deixam rastro visível no código-fonte.

Essa dependência dos dados cria duas classes principais de vulnerabilidade. A primeira opera no momento do treinamento: envenenamento de dados. Um adversário com acesso ao pipeline de coleta ou rotulação pode inserir exemplos maliciosos que induzem o modelo a aprender comportamentos específicos — um backdoor que permanece latente até ser ativado por um padrão de entrada controlado pelo atacante. Em ambientes onde dados são coletados de forma distribuída ou contínua, verificar a integridade do conjunto de treinamento é um problema em aberto. A segunda classe opera no momento da inferência: ataques adversariais. Perturbações pequenas e frequentemente imperceptíveis para humanos nos dados de entrada podem levar modelos a produzir previsões incorretas com alta confiança. O problema não é apenas que o modelo erra — é que erra de forma sistemática e controlável por um adversário, o que transforma uma limitação técnica em vetor de ataque deliberado.

Há uma terceira classe que opera em direção oposta: em vez de manipular o modelo, o adversário o usa para extrair informação. Ataques de inferência de associação exploram o comportamento do modelo para determinar se um exemplo específico estava no conjunto de treinamento. Ataques de reconstrução vão além e tentam recuperar exemplos individuais a partir das saídas do modelo. Quando o modelo foi treinado sobre dados sensíveis — registros médicos, dados financeiros, comunicações privadas — isso representa uma violação de privacidade que não decorre de nenhuma falha de criptografia ou controle de acesso, mas da capacidade do modelo de memorizar seus dados de treinamento.

Modelos disponibilizados como serviço introduzem ainda vulnerabilidades específicas ao contexto de produção. Acesso repetido à API permite que um adversário construa uma aproximação do modelo por consultas sucessivas — extração de modelo — sem acesso ao código ou aos pesos originais. Modelos generativos, em particular, podem ser manipulados para produzir saídas que violam políticas de uso, contornam filtros de segurança ou amplificam desinformação. E comportamentos inesperados em distribuições fora do treinamento — entradas que o modelo nunca viu — podem ser explorados de formas que os desenvolvedores não anteciparam.

O que atravessa todas essas classes de vulnerabilidade é algo que a resposta técnica sozinha não resolve: segurança em IA é um problema sociotécnico. Fatores humanos — uso inadequado, falta de compreensão dos sistemas, exploração por engenharia social, incentivos organizacionais que priorizam desempenho sobre robustez — determinam tanto a exposição a riscos quanto a efetividade das defesas. Um modelo tecnicamente robusto implantado por uma organização sem cultura de segurança é tão vulnerável quanto um modelo frágil em um ambiente bem gerido. Isso significa que defesas puramente algorítmicas são necessárias mas insuficientes: precisam ser acompanhadas de práticas de engenharia segura ao longo de todo o pipeline, mecanismos de monitoramento contínuo em produção, auditorias e políticas de controle de acesso que considerem o modelo como ativo sensível.

A dificuldade central é que o adversário e o desenvolvedor jogam um jogo assimétrico. Defender exige cobrir toda a superfície de ataque; atacar exige encontrar uma única brecha. Em sistemas que aprendem continuamente ou que operam em ambientes dinâmicos, essa superfície muda ao longo do tempo — e o modelo que era seguro na implantação pode não ser o mesmo modelo seis meses depois.

5.1. Como enfrentar os desafios de segurança em sistemas de Inteligência Artificial?

Enfrentar os desafios de segurança em IA exige aceitar a assimetria do problema: defender custa mais do que atacar, e a superfície de ataque inclui dados, modelos e infraestrutura simultaneamente. As respostas disponíveis operam em três frentes — robustez técnica, governança do pipeline e dimensão sociotécnica — e precisam avançar juntas. Fortalecer apenas uma delas deixa as outras expostas.

Para ataques adversariais, a resposta mais direta é o treinamento adversarial: incluir exemplos adversariais no processo de treinamento para que o modelo aprenda a resistir a perturbações. Funciona, mas tem custo computacional significativo e tende a reduzir desempenho em exemplos limpos — um trade-off que precisa ser explicitado. Certificação formal vai além e busca garantir matematicamente que o modelo produz a mesma previsão para qualquer entrada dentro de uma bola de perturbação definida. É mais robusta como garantia, mas escala mal para modelos grandes e domínios complexos. Na prática, a combinação de treinamento adversarial com monitoramento de entradas em produção — detectando distribuições anômalas antes que cheguem ao modelo — é a abordagem mais viável para a maioria dos contextos.

Para envenenamento de dados, a defesa começa antes do treinamento. Curadoria rigorosa, rastreabilidade de proveniência e verificação de integridade do pipeline de coleta são a primeira linha. Quando os dados vêm de fontes distribuídas ou não confiáveis, técnicas de aprendizado robusto — como agregação resistente a outliers e detecção de exemplos influentes — buscam identificar e isolar exemplos maliciosos antes que contaminem o modelo. Em aprendizado federado, onde o envenenamento pode vir de clientes individuais, métodos de detecção de clientes anômalos e agregação robusta atenuam o risco sem eliminar a dependência de premissas sobre o comportamento da maioria dos participantes.

Para vazamento de informações e ataques de inferência, as respostas vêm do campo de privacidade diferencial: adicionar ruído calibrado ao processo de treinamento de forma que o modelo não possa revelar com precisão se um exemplo específico estava nos dados de treinamento. A garantia é matemática e quantificável — o que a distingue de abordagens heurísticas — mas tem custo em utilidade: quanto mais forte a garantia de privacidade, maior a degradação de desempenho. Computação multipartidária segura e aprendizado federado com agregação segura oferecem alternativas para cenários onde os dados precisam permanecer distribuídos, mas introduzem overhead computacional e de comunicação que limita sua aplicabilidade em escala.

Para exploração de modelos disponibilizados como serviço, as defesas combinam limitação de acesso, detecção de comportamento anômalo de consultas e perturbação controlada das saídas para dificultar a reconstrução do modelo por consultas sucessivas. Nenhuma dessas medidas é impermeável — um adversário com recursos suficientes e acesso irrestrito à API pode eventualmente aproximar o modelo — mas aumentam o custo do ataque a ponto de torná-lo inviável na maioria dos cenários práticos.

A dimensão sociotécnica exige respostas que vão além do técnico. Integrar práticas de segurança ao ciclo de vida do desenvolvimento — testes adversariais sistemáticos, auditorias periódicas, revisão de pipeline de dados, políticas de controle de acesso que tratem o modelo como ativo sensível — é condição necessária mas insuficiente se a organização não tiver cultura de segurança. Equipes que desenvolvem sistemas de IA para aplicações críticas precisam de formação específica em segurança adversarial, não apenas em desempenho preditivo. E mecanismos de monitoramento contínuo em produção são indispensáveis: um modelo seguro na implantação pode não ser o mesmo modelo depois de retreinamento incremental ou de mudanças na distribuição dos dados de entrada.

O limite de todas essas abordagens é o mesmo: são respostas reativas a classes de ataque conhecidas. A pesquisa em segurança adversarial é um campo em que ofensa e defesa coevoluem — cada nova defesa gera novos ataques projetados para contorná-la. Isso não invalida as defesas disponíveis, mas impõe humildade sobre o que é possível garantir. Sistemas de IA em aplicações críticas precisam ser projetados com a premissa de que serão atacados de formas que seus desenvolvedores não anteciparam — e que resiliência, monitoramento e capacidade de resposta rápida importam tanto quanto robustez estática.

6. Quais são os principais desafios na avaliação de sistemas de Inteligência Artificial?

Avaliar sistemas de IA é mais difícil do que parece, e a dificuldade não é acidental. Em sistemas tradicionais de software, avaliação é verificação: o sistema faz o que foi especificado? Em sistemas de IA, não há especificação completa do comportamento esperado — há dados, há métricas e há a esperança de que o desempenho observado em condições controladas prediz o desempenho em condições reais. Essa esperança frequentemente falha, e entender por que é o ponto de partida para qualquer discussão séria sobre avaliação.

O problema mais fundamental é que métricas agregadas mentem por omissão. Acurácia, F1, AUC — todas são médias, e médias ocultam o que importa. Um modelo com 92% de acurácia global pode ter 61% de acurácia para um subgrupo específico, e essa discrepância só aparece quando a avaliação é desagregada por grupo, contexto ou região do espaço de entrada. Em aplicações de alto impacto — triagem médica, concessão de crédito, reconhecimento facial — a diferença entre desempenho médio e desempenho por subgrupo não é um detalhe metodológico: é a diferença entre um sistema que funciona para todos e um sistema que funciona bem para a maioria e falha sistematicamente para os mais vulneráveis. Métricas agregadas não são erradas — são insuficientes.

O segundo problema é que avaliação estática não avalia o que importa em produção. Modelos são tipicamente validados em dados que seguem distribuição semelhante à do treinamento, em condições controladas, num momento específico do tempo. Em produção, a distribuição muda, os usuários se adaptam ao sistema, o contexto evolui. Um modelo validado hoje pode estar degradado em seis meses sem que nenhum alerta técnico tenha sido disparado. Isso exige avaliação pós-implantação e monitoramento contínuo — não como complemento opcional à avaliação tradicional, mas como parte integrante do processo.

A natureza multiobjetivo da avaliação é o terceiro eixo de dificuldade, e talvez o mais estrutural. Desempenho preditivo, robustez adversarial, equidade entre grupos, interpretabilidade e eficiência computacional raramente podem ser maximizados simultaneamente — há trade-offs reais e documentados entre eles. Modelos mais acurados tendem a ser menos interpretáveis. Garantias de equidade entre grupos frequentemente reduzem desempenho médio. Robustez adversarial tem custo em acurácia em exemplos limpos. Isso significa que avaliar um sistema de IA exige escolher entre critérios que competem entre si, e essa escolha tem natureza normativa, não técnica. Não há métrica única que resolva o problema — há decisões sobre o que priorizar em cada contexto, e essas decisões precisam ser tornadas explícitas.

Modelos generativos e sistemas baseados em linguagem natural introduzem uma camada adicional de dificuldade. O que significa avaliar a qualidade de um texto gerado? Métricas automáticas como BLEU e ROUGE medem similaridade superficial com referências humanas, mas capturam mal coerência, veracidade, utilidade e tom. Avaliação humana é mais válida mas cara, lenta e sujeita a vieses de quem avalia. Modelos de avaliação baseados em LLMs — usar um modelo para avaliar outro — emergem como alternativa promissora, mas introduzem circularidade: o modelo avaliador tem seus próprios vieses, e avaliar a qualidade da avaliação é um problema recursivo sem solução trivial.

Reprodutibilidade é um problema sério que a área tende a subestimar. Resultados dependem de inicialização aleatória, versão de biblioteca, hardware utilizado e, frequentemente, de detalhes de implementação que não constam nos artigos. Benchmarks públicos criam um problema adicional: quando os dados de teste são públicos e os modelos são treinados iterativamente com base em resultados publicados, contamina-se progressivamente a separação entre treino e teste — o modelo não generaliza para dados novos, generaliza para aquele benchmark específico. Isso infla artificialmente o progresso reportado e dificulta comparações honestas entre métodos.

O que atravessa todos esses problemas é uma tensão que a área ainda não resolveu: avaliar bem é caro, lento e contextual, mas a pressão por resultados rápidos e comparáveis favorece métricas simples em benchmarks padronizados. Essa pressão não é neutra — ela molda o que é pesquisado, o que é publicado e o que é implantado. Avançar em avaliação exige tanto desenvolvimento técnico de novas métricas e protocolos quanto uma mudança de cultura sobre o que conta como evidência de que um sistema funciona.

6.1. Como enfrentar os desafios na avaliação de sistemas de Inteligência Artificial?

Não há solução única para os desafios de avaliação em IA — o que há é um conjunto de respostas parciais, cada uma endereçando uma dimensão específica do problema. O risco mais comum não é desconhecê-las, mas tratá-las como suficientes quando não são. Avaliar bem continua sendo caro, contextual e irredutivelmente dependente de decisões normativas sobre o que importa medir.

Para o problema de métricas agregadas, a resposta mais direta é desagregação sistemática: reportar desempenho por subgrupo, contexto e região do espaço de entrada, em vez de apenas médias globais. Isso exige que os dados de avaliação sejam suficientemente representativos dos subgrupos relevantes — o que remete ao problema de curadoria discutido no contexto de dados. Iniciativas como *disaggregated evaluation* e *model cards* propõem esquemas padronizados de reporte que tornam essas diferenças visíveis e comparáveis entre sistemas. O limite é que desagregar exige saber de antemão quais subgrupos importam — e em aplicações novas, essa decisão não é óbvia.

Para a dependência de conjuntos de teste estáticos, a resposta envolve ampliar o escopo da avaliação para além da distribuição de treinamento. Testes fora de distribuição (*out-of-distribution evaluation*) submetem o modelo a entradas que deliberadamente diferem do que foi visto durante o treinamento, revelando como o desempenho degrada com a distância distribucional. Avaliação sob perturbações — incluindo perturbações adversariais, ruído natural e variações de estilo — complementa essa perspectiva. Para ambientes dinâmicos, monitoramento contínuo em produção é indispensável: métricas de desempenho calculadas sobre dados reais ao longo do tempo, com alertas automáticos para degradação e mecanismos de retreinamento quando necessário. Isso transforma avaliação de evento pontual em processo contínuo.

Para a natureza multiobjetivo, não existe solução técnica que elimine os trade-offs — eles precisam ser tornados explícitos e decididos. Frameworks de avaliação multiobjetivo permitem visualizar fronteiras de Pareto entre critérios que competem, tornando visível o custo de cada escolha. *Model cards* e *datasheets* contribuem aqui também: ao documentar explicitamente para que contextos o modelo foi avaliado e quais trade-offs foram feitos, permitem que usuários e reguladores tomem decisões informadas sobre adequação ao uso. O que não é aceitável — mas é comum — é ocultar esses trade-offs em escolhas de implementação que ninguém examina.

Para avaliação de modelos generativos e sistemas de linguagem natural, o campo ainda está construindo suas respostas. Métricas baseadas em modelos — usar um LLM para avaliar a qualidade da saída de outro LLM — emergiram como alternativa promissora a métricas de similaridade superficial como BLEU e ROUGE, mas introduzem circularidade e vieses próprios que precisam ser caracterizados. Avaliação humana continua sendo o padrão mais válido para aspectos como coerência, veracidade e utilidade, mas é cara e não escala. A abordagem mais robusta combina as duas: avaliação humana para calibrar e validar métricas automáticas, e métricas automáticas para escalar a avaliação rotineira. Benchmarks específicos de domínio — que avaliam capacidades relevantes para o contexto de uso real, não capacidades genéricas — são mais informativos do que benchmarks de propósito geral, mas exigem investimento para construir e manter.

Para reprodutibilidade, as respostas são mais maduras e mais ignoradas do que deveriam. Reportar não apenas resultados médios mas variância entre execuções, sementes aleatórias utilizadas, versões exatas de bibliotecas e hardware são práticas estabelecidas que a pressão por publicação frequentemente dispensa. Separação estrita entre dados de desenvolvimento e dados de teste — com dados de teste mantidos privados até o momento da avaliação final — é condição necessária para benchmarks que medem generalização real e não memorização do benchmark.

Iniciativas como *Papers with Code* e reprodutibilidade como critério explícito de revisão em conferências avançam nessa direção, mas a mudança de cultura é lenta.

O que atravessa todas essas frentes é uma constatação que as respostas técnicas sozinhas não resolvem: avaliação é uma escolha sobre o que valorizar, e essa escolha tem consequências distribuídas de forma desigual. Sistemas avaliados apenas por acurácia média em benchmarks padronizados tendem a ser implantados em contextos para os quais não foram adequadamente testados, falhando justamente para os grupos que mais precisariam de sistemas confiáveis. Avançar em avaliação exige tanto desenvolver melhores métricas e protocolos quanto construir a cultura institucional e os incentivos que tornam sua adoção a norma, não a exceção.

7. Quais são os principais desafios atuais em cibersegurança?

Cibersegurança é um problema de assimetria. Defender exige proteger toda a superfície de ataque, continuamente, sem falhar uma vez. Atacar exige encontrar uma única brecha, no momento certo. Essa assimetria é estrutural e não desaparece com mais tecnologia ou mais investimento — ela define o caráter dos desafios da área e explica por que eles resistem a soluções definitivas.

A superfície de ataque nunca parou de crescer. Computação em nuvem, Internet das Coisas, sistemas distribuídos e cadeias de suprimentos de software e hardware expandiram o perímetro a defender de forma que os modelos tradicionais de segurança baseados em perímetro fixo se tornaram inadequados. Um sistema moderno depende de componentes desenvolvidos por dezenas de fornecedores, executando em infraestrutura que a organização não controla, acessado por usuários em dispositivos que ela não gerencia. Cada dependência é uma superfície. O ataque à SolarWinds ilustrou isso com brutalidade: uma única atualização de software legítima, comprometida na origem, contaminou milhares de organizações simultaneamente — incluindo agências governamentais — sem que nenhum sistema de detecção perimetral pudesse interceptá-la, porque a ameaça entrou pelo canal autorizado.

A evolução das ameaças segue uma lógica própria. Ataques tornaram-se mais sofisticados não apenas tecnicamente, mas organizacionalmente: grupos de ransomware operam como empresas, com divisão de trabalho, suporte a clientes e modelos de negócio baseados em extorsão dupla — cifram os dados e ameaçam publicá-los. O uso de IA por agentes maliciosos amplifica essa capacidade: geração automatizada de phishing personalizado, identificação de vulnerabilidades em escala e adaptação de ataques em tempo real tornam a detecção baseada em assinaturas cada vez menos eficaz. A defesa que funcionava ontem pode não funcionar hoje, e o ciclo de atualização do lado do atacante é mais rápido do que o do lado do defensor.

A criptografia pós-quântica é um desafio de horizonte, mas urgente. Algoritmos criptográficos amplamente utilizados — RSA, ECDSA, Diffie-Hellman — baseiam-se em problemas computacionalmente difíceis para computadores clássicos que se tornam tratáveis com algoritmos quânticos como o de Shor. Computadores quânticos de escala suficiente para quebrar esses esquemas ainda não existem, mas o risco é presente: adversários com recursos suficientes já coletam dados criptografados hoje com a intenção de decifrá-los quando a capacidade quântica estiver disponível. A migração para algoritmos pós-quânticos — cujos primeiros padrões foram publicados pelo NIST em 2024 — é um processo lento, caro e tecnicamente complexo que precisa começar antes que a ameaça se concretize.

Os fatores humanos são, empiricamente, o vetor de ataque mais explorado. A maioria dos incidentes de segurança documentados tem componente humano: credenciais comprometidas por phishing, configurações incorretas de infraestrutura em nuvem, privilégios excessivos concedidos por conveniência, ausência de autenticação multifator em sistemas críticos. Isso não é falha individual — é consequência de sistemas projetados para funcionar, não para ser seguros, e de organizações que tratam segurança como restrição e não como requisito. A engenharia social explora não vulnerabilidades técnicas, mas padrões humanos de confiança e urgência que são difíceis de eliminar por treinamento.

A detecção e resposta a incidentes enfrenta o problema do volume e do ruído. Sistemas modernos geram quantidades de logs e eventos que nenhuma equipe humana consegue analisar em tempo real. Distinguir comportamento malicioso de comportamento legítimo anômalo em ambientes complexos e dinâmicos exige técnicas avançadas de análise comportamental e aprendizado de máquina — mas modelos de detecção têm taxas de falso positivo que, em escala, geram alertas em volume que paralisa as equipes de resposta. O problema não é apenas detectar ataques, mas detectá-los com precisão suficiente para que a resposta seja viável.

O que atravessa todos esses desafios é a inadequação do modelo mental de segurança como estado a atingir. Segurança não é um problema que se resolve — é um processo que se mantém. Sistemas seguros hoje podem não ser seguros amanhã, não porque algo foi feito errado, mas porque o ambiente mudou, novas vulnerabilidades foram descobertas ou o modelo de ameaça evoluiu. Aceitar isso tem implicações práticas: monitoramento contínuo, atualização permanente, capacidade de resposta rápida e tolerância a falhas são tão importantes quanto as defesas estáticas. E tem implicações organizacionais: segurança não é responsabilidade exclusiva de uma equipe técnica — é uma propriedade que emerge de decisões de arquitetura, cultura organizacional e governança que atravessam toda a instituição.

7.1. Como enfrentar os principais desafios atuais em cibersegurança?

Enfrentar os desafios de cibersegurança exige abandonar a ideia de que existe um estado de segurança a atingir. As respostas disponíveis não eliminam os problemas — reduzem superfícies de ataque, aumentam o custo do ataque para o adversário e melhoram a capacidade de detectar e responder quando algo falha. Essa distinção importa: organizações que tratam segurança como projeto a concluir tendem a ser mais vulneráveis do que aquelas que a tratam como processo contínuo.

Para o problema da superfície de ataque crescente, a resposta mais influente dos últimos anos é a arquitetura de confiança zero (*zero trust*). Em vez de assumir que tudo dentro do perímetro é confiável, confiança zero parte da premissa de que nenhum usuário, dispositivo ou serviço é confiável por padrão — autenticação e autorização são verificadas continuamente, com privilégios mínimos concedidos para cada operação específica. Isso não elimina ataques, mas limita o raio de dano quando uma credencial é comprometida ou um componente é violado. A implementação em organizações com infraestrutura legada é complexa e cara, mas o modelo tem se consolidado como direção para arquiteturas modernas de segurança.

Para a cadeia de suprimentos, as respostas combinam verificação de integridade, rastreabilidade e redução de dependências desnecessárias. Iniciativas como *Software Bill of Materials* (SBOM) — inventários formais de todos os componentes de software utilizados em um sistema, incluindo dependências transitivas — permitem identificar rapidamente quais sistemas são afetados quando uma vulnerabilidade é descoberta em uma biblioteca específica. Assinatura criptográfica de artefatos de software e verificação de integridade em pipelines de entrega contínua reduzem a janela de oportunidade para ataques como o da SolarWinds. O limite é que essas práticas dependem de adoção coordenada ao longo de toda a cadeia — e fornecedores com menos recursos ou incentivos tendem a ser os elos mais fracos.

Para a evolução das ameaças e a automação de ataques, a resposta é usar as mesmas ferramentas do adversário na defesa. Sistemas de detecção baseados em análise comportamental e aprendizado de máquina identificam padrões anômalos que escapam a regras estáticas, adaptando-se a ameaças novas sem depender de assinaturas conhecidas. Inteligência de ameaças (*threat intelligence*) compartilhada entre organizações e setores permite que a detecção de um ataque em uma organização beneficie outras antes que o mesmo ataque se propague. O problema é o ruído: modelos de detecção que geram muitos falsos positivos paralisam equipes de resposta, tornando necessário calibrar precisão e recall de acordo com o custo relativo de cada tipo de erro no contexto específico.

Para a transição criptográfica pós-quântica, a resposta é começar agora, mesmo que a ameaça ainda não seja imediata. O NIST publicou em 2024 os primeiros padrões de algoritmos pós-quânticos — CRYSTALS-Kyber para troca de chaves e CRYSTALS-Dilithium para assinaturas digitais — e a migração para esses algoritmos em sistemas críticos precisa ser planejada com antecedência. Isso envolve identificar onde criptografia assimétrica é utilizada, avaliar o custo de migração em cada contexto e priorizar sistemas que protegem dados sensíveis de longo prazo. Criptografia híbrida — combinar algoritmos clássicos e pós-quânticos em paralelo durante a transição — oferece proteção imediata sem exigir migração completa de uma vez.

Para fatores humanos, as respostas mais eficazes não são as mais óbvias. Treinamento de conscientização tem efeito limitado quando o ambiente de trabalho penaliza quem reporta incidentes ou quando processos de segurança são tão inconvenientes que os usuários desenvolvem workarounds. Design centrado no usuário — tornar o comportamento seguro o caminho de menor resistência, não o de maior — produz resultados mais duradouros do que campanhas de phishing simulado. Autenticação multifator, gestão de senhas por gerenciadores e privilégios mínimos aplicados por padrão reduzem a dependência de comportamento humano perfeito, que é uma premissa irrealista.

Para detecção e resposta, a resposta ao problema do volume é automação seletiva e triagem inteligente. Plataformas de SOAR (*Security Orchestration, Automation and Response*) automatizam respostas a incidentes de baixa complexidade — isolamento de endpoint comprometido, bloqueio de IP malicioso, revogação de credencial — liberando equipes humanas para incidentes que exigem julgamento. Exercícios regulares de simulação de incidentes (*red team/blue team* e *tabletop exercises*) treinam capacidade de resposta antes que seja necessária em condições reais, revelando lacunas de processo que só aparecem sob pressão.

O que atravessa todas essas frentes é uma constatação que nenhuma solução técnica resolve sozinha: segurança é uma propriedade organizacional antes de ser uma propriedade técnica. Arquiteturas bem projetadas falham em organizações com cultura de segurança fraca. Ferramentas sofisticadas são ineficazes sem equipes treinadas para operá-las. E investimento em segurança tende a ser insuficiente até que um incidente grave torne o custo da insuficiência visível — geralmente tarde demais. Mudar isso exige que segurança seja tratada como requisito de negócio, não como overhead técnico, com governança, métricas e responsabilização que reflitam essa prioridade.

8. Como a Inteligência Artificial e a cibersegurança se relacionam?

A relação entre IA e cibersegurança é coevolutiva — e isso significa algo preciso. Não é apenas que as duas áreas se influenciam mutuamente; é que avanços em uma alimentam diretamente avanços na outra, num ciclo sem ponto de equilíbrio estável. As mesmas capacidades que tornam IA útil para defesa — reconhecimento de padrões em escala, geração de conteúdo, automação de decisões — são igualmente úteis para ataque. Não há vantagem técnica que pertença exclusivamente a um lado.

Do lado da defesa, IA resolveu problemas que escala humana não consegue resolver. Sistemas modernos geram volumes de logs, eventos e alertas que nenhuma equipe de analistas consegue processar em tempo real. Modelos de detecção de anomalias identificam comportamentos suspeitos em tráfego de rede, acessos a sistemas e sequências de eventos que escapariam a regras estáticas, adaptando-se a padrões novos sem depender de assinaturas conhecidas. Em análise de malware, modelos treinados sobre características comportamentais detectam variantes de ameaças conhecidas que teriam evadido detecção baseada em assinatura. Em triagem de vulnerabilidades, IA permite priorizar o que precisa ser corrigido com urgência num universo de CVEs que cresce mais rápido do que qualquer equipe consegue acompanhar manualmente. O ganho não é apenas velocidade — é a capacidade de operar em escala que antes era inviável.

Do lado do ataque, as mesmas capacidades são aplicadas com objetivos opostos. Phishing personalizado gerado por LLMs é indistinguível de comunicação legítima a um grau que os ataques genéricos de uma década atrás não

alcançavam — e pode ser produzido em volume industrial, adaptado ao perfil específico de cada alvo a partir de informações publicamente disponíveis. Deepfakes de voz e vídeo comprometem processos de autenticação baseados em biometria e criam evidências falsas convincentes. Modelos de linguagem auxiliam na descoberta automatizada de vulnerabilidades em código, acelerando o lado ofensivo do ciclo de exploração. Malware adaptativo usa técnicas de aprendizado para modificar seu comportamento e evadir sistemas de detecção que não viram aquela variante específica. A IA não inventou essas categorias de ataque — ela as tornou mais baratas, mais rápidas e mais acessíveis.

A consequência mais importante dessa dualidade é que sistemas de IA usados para defesa são eles próprios alvos. Um modelo de detecção de intrusão pode ser atacado adversarialmente — entradas cuidadosamente construídas que o modelo classifica como benignas, mas que carregam comportamento malicioso. Um sistema de autenticação biométrica pode ser enganado por deepfakes. Um modelo de triagem de vulnerabilidades pode ser envenenado durante o treinamento para ignorar classes específicas de ameaças. Isso cria uma cadeia de dependência preocupante: quanto mais a defesa depende de IA, maior a superfície de ataque que essa dependência introduz.

Há ainda uma dimensão de governança que a dualidade torna urgente. Sistemas de IA em produção em contextos de segurança tomam decisões com consequências reais — bloquear acesso, isolar sistemas, escalar alertas — sem supervisão humana em tempo real, porque a escala que justifica seu uso torna essa supervisão inviável. Definir quando a automação é adequada, como auditar decisões tomadas por modelos e quem responde por erros são questões que a área ainda está construindo respostas.

8.1. Como enfrentar os desafios na interseção entre Inteligência Artificial e cibersegurança?

Enfrentar os desafios na interseção entre IA e cibersegurança exige reconhecer que não há posição defensiva estável. O ciclo coevolutivo não para — cada resposta defensiva informa o próximo movimento ofensivo, e vice-versa. As respostas disponíveis não resolvem essa assimetria; elas aumentam o custo do ataque, reduzem o tempo de detecção e melhoram a capacidade de recuperação quando algo falha.

Para fortalecer o uso defensivo de IA, o foco tem sido desenvolver modelos mais robustos a evasão e mais calibrados em suas previsões. Robustez adversarial — treinar modelos com exemplos adversariais para que aprendam a resistir a perturbações — é a resposta mais direta para sistemas de detecção que podem ser enganados por entradas manipuladas. Calibração de incerteza importa aqui de forma específica: um sistema de detecção que expressa alta confiança em classificações erradas é mais perigoso do que um que admite incerteza, porque suprime a revisão humana justamente quando ela seria necessária. Ensembles de modelos com diferentes arquiteturas e dados de treinamento são mais difíceis de atacar simultaneamente do que modelos únicos, porque transferência adversarial entre arquiteturas distintas é imperfeita.

Para a ameaça de ataques gerados por IA, a defesa mais eficaz combina detecção técnica com redesenho de processos. Do lado técnico, detectores de conteúdo gerado por IA — para texto, áudio e vídeo — evoluem em paralelo com os geradores, numa corrida que nenhum lado vence definitivamente. Do lado de processo, autenticação multifator robusta, verificação fora de banda para transações críticas e protocolos que não dependem exclusivamente de reconhecimento de identidade por conteúdo reduzem a eficácia de deepfakes e phishing personalizado independentemente de quão convincentes sejam. A premissa de que comunicação legítima pode ser verificada por conteúdo está se tornando insustentável — processos de segurança precisam ser redesenhados com essa premissa em mente.

Para proteger sistemas de IA usados em defesa, as respostas vêm do campo de segurança adversarial em ML. Monitoramento de distribuição de entrada detecta quando o modelo está recebendo entradas que diferem sistematicamente do que foi treinado — sinal de possível ataque adversarial ou envenenamento. Verificação de integridade de dados de treinamento e pipelines de atualização de modelos reduz a janela para envenenamento em sistemas que aprendem continuamente. Avaliação regular de robustez — submeter o sistema a ataques conhecidos em ambiente controlado — revela degradação antes que seja explorada em produção.

Para inteligência de ameaças, o compartilhamento entre organizações e setores é a resposta mais subutilizada. Indicadores de comprometimento, padrões de ataque e técnicas de evasão descobertos em uma organização podem beneficiar outras antes que o mesmo ataque se propague — mas dependem de estruturas de confiança e incentivos para compartilhamento que frequentemente não existem. Plataformas como MITRE ATT&CK oferecem frameworks comuns para descrever e compartilhar conhecimento sobre táticas e técnicas de ataque, reduzindo a fragmentação da inteligência de ameaças.

Para governança, a resposta mais honesta é que ainda está sendo construída. Sistemas de IA em contextos de segurança precisam de trilhas de auditoria que permitam reconstruir por que uma decisão foi tomada, mecanismos de supervisão humana para classes de decisão de alto impacto e processos claros de responsabilização quando erros ocorrem. Integrar práticas de segurança adversarial ao ciclo de vida do desenvolvimento — testes de robustez antes da implantação, monitoramento contínuo em produção, protocolos de resposta quando modelos são comprometidos — é condição necessária que poucos processos de desenvolvimento de IA incorporam sistematicamente.

O que a coevolução entre IA ofensiva e defensiva torna claro é que vantagem técnica é temporária. A resposta mais duradoura não é ter o melhor modelo de detecção — é ter a organização mais capaz de aprender rápido, adaptar defesas e responder efetivamente quando algo falha. Resiliência e capacidade de adaptação importam mais do que robustez estática, porque o ambiente de ameaças muda mais rápido do que qualquer solução técnica consegue acompanhar.

9. Qual é o papel dos fatores humanos na cibersegurança e quais desafios estão associados?

A maioria dos incidentes de segurança documentados tem componente humano. Não é uma estimativa imprecisa — relatórios anuais de empresas como Verizon e IBM consistentemente apontam que entre 70% e 90% dos incidentes

envolvem phishing, credenciais comprometidas, configuração incorreta ou erro operacional. Isso não significa que as pessoas são o problema; significa que sistemas de segurança foram projetados com premissas sobre comportamento humano que não se sustentam em condições reais. A distinção importa porque leva a respostas diferentes: se o problema é humano, a solução é treinamento; se o problema é de design, a solução é redesenhar os sistemas.

Engenharia social é o vetor mais explorado porque ataca algo que não tem patch. Phishing, pretexting e BEC (*Business Email Compromise*) exploram mecanismos cognitivos universais — autoridade, urgência, reciprocidade, familiaridade — que evoluíram para facilitar cooperação social e que um adversário competente consegue acionar de forma confiável. Um email que simula uma solicitação urgente do CEO para transferência bancária não explora ignorância; explora o mesmo circuito que faz qualquer pessoa responder mais rápido a um pedido de um superior sob pressão de tempo. Treinamento de conscientização reduz a taxa de cliques em simulações de phishing, mas o efeito decai rapidamente e não transfere bem para variantes novas. A defesa mais eficaz não é tornar usuários imunes a engenharia social — é projetar processos que não dependam dessa imunidade.

A tensão entre segurança e usabilidade é o problema central dos fatores humanos, e é sistematicamente subestimado. Sistemas seguros que ninguém usa são ineficazes. Quando autenticação multifator é inconveniente demais, usuários compartilham tokens. Quando políticas de senha são complexas demais, usuários as anotam em post-its. Quando processos de aprovação de acesso são lentos demais, usuários constroem workarounds com privilégios excessivos que nunca são revogados. Esses comportamentos não são falhas de caráter — são respostas racionais a sistemas que colocam o ônus da segurança sobre o usuário sem reconhecer os custos que isso impõe. O princípio do caminho de menor resistência se aplica aqui: comportamento seguro precisa ser o comportamento conveniente, não o comportamento que exige esforço adicional.

Configuração incorreta de sistemas é um problema de escala e complexidade, não de negligência. Infraestrutura em nuvem moderna envolve centenas de parâmetros de segurança, permissões granulares e interações entre serviços que nenhum administrador consegue acompanhar completamente. Buckets S3 públicos, bancos de dados sem autenticação e chaves de API expostas em repositórios são consequências previsíveis de sistemas cuja superfície de configuração excede a capacidade humana de auditoria manual. O problema não é que os administradores não sabem o que estão fazendo — é que a complexidade dos sistemas tornou impossível fazer tudo certo o tempo todo sem automação.

O comportamento organizacional determina o teto do que qualquer solução técnica pode alcançar. Organizações que penalizam quem reporta incidentes criam incentivos para ocultar erros até que se tornem crises. Organizações sem processos claros de revogação de acesso acumulam privilégios excessivos de ex-funcionários e fornecedores. Organizações que tratam segurança como responsabilidade exclusiva de uma equipe de TI produzem culturas onde o restante da organização não sente responsabilidade pelo próprio comportamento. Nenhuma ferramenta de segurança corrige esses problemas — eles exigem mudança de governança e cultura institucional.

9.1. Como enfrentar os desafios associados aos fatores humanos na cibersegurança?

Enfrentar os desafios de fatores humanos em cibersegurança exige mudar o enquadramento do problema. A pergunta não é como fazer usuários se comportarem de forma mais segura — é como projetar sistemas e processos em que comportamento seguro seja o caminho de menor resistência. Essa distinção muda completamente o que conta como resposta adequada.

Para engenharia social, a defesa mais eficaz não é imunizar usuários contra manipulação — é remover da equação a possibilidade de que um único usuário manipulado cause dano catastrófico. Autenticação multifator resistente a phishing — chaves de segurança físicas como FIDO2, que verificam o domínio legítimo antes de liberar a credencial, em vez de códigos SMS que podem ser interceptados — elimina a eficácia do phishing de credenciais independentemente de quão convincente seja o ataque. Verificação fora de banda para transações financeiras críticas — confirmar por canal independente antes de executar — reduz a eficácia de BEC sem depender de que o usuário detecte o ataque. O princípio geral é substituir dependência de julgamento humano sob pressão por processos que funcionam mesmo quando o julgamento falha.

Para usabilidade, a resposta é design centrado no usuário aplicado com rigor a mecanismos de segurança — o que a área ainda faz de forma insuficiente. Gerenciadores de senha eliminam o trade-off entre senhas seguras e senhas memoráveis, tornando o comportamento seguro mais conveniente do que a alternativa. Single sign-on reduz o número de credenciais que um usuário precisa gerenciar sem reduzir segurança. Autenticação multifator bem implementada — que aparece apenas quando necessária, não em cada login de baixo risco — mantém proteção sem impor fricção constante. O teste empírico é simples: se o processo de segurança tem um workaround óbvio que usuários descobrem rapidamente, o problema é de design, não de comportamento.

Para configuração incorreta de sistemas, a resposta é automação e auditoria contínua, não treinamento de administradores. Ferramentas de *Cloud Security Posture Management* (CSPM) identificam automaticamente configurações incorretas em infraestrutura em nuvem — permissões excessivas, recursos expostos publicamente, chaves não rotacionadas — antes que sejam exploradas. Infraestrutura como código, com revisão automatizada de segurança no pipeline de entrega, torna configuração auditável e reversível. Princípio do privilégio mínimo aplicado por padrão — acesso concedido especificamente para cada tarefa, com revogação automática após conclusão — reduz a superfície de dano quando uma credencial é comprometida.

Para comportamento organizacional, as respostas são institucionais antes de serem técnicas. Programas de reporte de incidentes sem punição — onde erros reportados são tratados como informação valiosa, não como evidência de falha individual — criam incentivos para que problemas sejam visíveis antes de se tornarem crises. Processos formais de offboarding que incluem revogação imediata de acessos eliminam uma das fontes mais comuns de privilégios excessivos. Simulações regulares de incidentes — tabletop exercises que envolvem liderança, não apenas

equipes técnicas — constroem capacidade de resposta e tornam segurança uma responsabilidade compartilhada, não delegada.

Confiança zero é a resposta arquitetural mais abrangente para a impossibilidade de eliminar erro humano. Em vez de assumir que usuários autenticados dentro do perímetro são confiáveis, confiança zero verifica continuamente identidade, dispositivo e contexto para cada acesso, concedendo privilégios mínimos para cada operação específica. O efeito sobre fatores humanos é direto: uma credencial comprometida ou um usuário manipulado por engenharia social não concede acesso irrestrito — concede acesso limitado ao que aquela credencial, naquele dispositivo, naquele contexto, estava autorizada a fazer. O raio de dano de qualquer erro humano individual é estruturalmente limitado pela arquitetura, não pela esperança de comportamento perfeito.

O que atravessa todas essas respostas é uma premissa comum: segurança que depende de usuários não errarem é segurança frágil. Sistemas robustos são projetados para falhar de forma segura quando o comportamento humano é imperfeito — porque ele sempre será. Isso não elimina a importância de treinamento e cultura, mas inverte a prioridade: primeiro projetar sistemas que tolerem erro humano, depois investir em reduzir a frequência desse erro.

10. Quais são os impactos da computação quântica na computação moderna?

Computação quântica não é uma versão mais rápida de computação clássica. É um modelo diferente de processamento, que explora superposição e entrelaçamento para realizar certas computações de formas que computadores clássicos não conseguem replicar eficientemente. A distinção importa porque o impacto não é uniforme: para a maioria dos problemas computacionais, computadores quânticos não oferecem vantagem relevante. Para uma classe específica de problemas, a vantagem é exponencial — e é exatamente nessa classe que vivem os fundamentos da criptografia moderna.

O algoritmo de Shor fatoriza inteiros em tempo polinomial num computador quântico. Num computador clássico, o melhor algoritmo conhecido é subexponencial mas ainda intratável para chaves suficientemente grandes. RSA, ECDSA e Diffie-Hellman — os esquemas que protegem a maior parte das comunicações digitais, transações financeiras e autenticação na internet — baseiam-se nessa intratabilidade clássica. Um computador quântico de escala suficiente os quebra. O algoritmo de Grover oferece aceleração quadrática em buscas não estruturadas, o que enfraquece — mas não quebra — cifras simétricas como AES, bastando dobrar o tamanho das chaves para compensar.

O problema é que computadores quânticos de escala suficiente para executar o algoritmo de Shor contra chaves RSA de 2048 bits ainda não existem. Os sistemas atuais, com algumas centenas de qubits físicos e taxas de erro ainda altas, estão a anos ou décadas de distância dessa capacidade. Mas isso não torna a ameaça futura — e a razão é o ataque de "harvest now, decrypt later". Adversários com recursos suficientes já coletam hoje dados criptografados com a intenção de decifrá-los quando a capacidade quântica estiver disponível. Dados que precisam permanecer confidenciais por décadas — segredos de Estado, registros médicos, propriedade intelectual de longo prazo — já estão em risco, porque o prazo de validade da criptografia atual pode ser menor do que o prazo de sigilo exigido.

O hardware quântico enfrenta obstáculos físicos que tornam a escala extraordinariamente difícil. Qubits são frágeis: qualquer interação com o ambiente introduz erros por decoerência, e manter coerência quântica por tempo suficiente para computações úteis exige isolamento extremo — temperaturas próximas ao zero absoluto, blindagem eletromagnética, vácuo. Correção de erros quântica exige redundância massiva: estimativas atuais sugerem que um qubit lógico livre de erros pode exigir entre mil e dez mil qubits físicos, dependendo da arquitetura e da taxa de erro aceitável. Os maiores sistemas disponíveis hoje têm algumas centenas de qubits físicos com qualidade insuficiente para correção de erros efetiva. A distância entre o estado atual e aplicações criptograficamente relevantes é substancial — mas a velocidade de progresso nos últimos cinco anos tornou previsões de longo prazo arriscadas.

Para simulação quântica — simular sistemas físicos e químicos quânticos — a vantagem é mais próxima e menos controversa. Moléculas e materiais são sistemas quânticos; simulá-los classicamente exige aproximações que degradam precisão ou recursos exponenciais. Computadores quânticos de escala intermediária, mesmo com erros, podem oferecer vantagem para problemas específicos de química computacional, design de materiais e descoberta de fármacos antes de qualquer vantagem criptográfica ser relevante. É nesse domínio que aplicações práticas de curto e médio prazo são mais prováveis.

As implicações geopolíticas são concretas e já em curso. EUA, China e União Europeia investem bilhões em programas nacionais de computação quântica, reconhecendo que supremacia nessa tecnologia tem consequências diretas para segurança nacional, inteligência e vantagem industrial. Quem quebrar primeiro a criptografia assimétrica atual — ou quem primeiro migrar sua infraestrutura crítica para algoritmos resistentes — terá vantagem estratégica significativa. Para o Brasil, como para a maioria dos países sem programas quânticos robustos, isso se traduz em dependência tecnológica numa área onde a soberania em criptografia é condição de soberania digital.

10.1. Como enfrentar os impactos da computação quântica na computação moderna?

Os impactos da computação quântica se manifestam em horizontes temporais diferentes, e as respostas precisam ser calibradas para cada horizonte. O risco criptográfico é urgente agora, mesmo sem computadores quânticos de grande escala existindo. As oportunidades em simulação e otimização são de médio prazo. A questão de infraestrutura e formação de recursos humanos é de longo prazo. Tratar os três com a mesma urgência ou com o mesmo descaso são erros simétricos.

A resposta mais urgente é a migração criptográfica pós-quântica, e ela precisa começar antes que a ameaça se concretize. O NIST concluiu em 2024 um processo de padronização de algoritmos resistentes a ataques quânticos, publicando padrões baseados em problemas de reticulados — CRYSTALS-Kyber para encapsulamento de chaves e

CRYSTALS-Dilithium para assinaturas digitais — considerados difíceis tanto para computadores clássicos quanto quânticos. A migração para esses algoritmos em sistemas críticos é um processo longo: envolve identificar onde criptografia assimétrica é usada, avaliar compatibilidade e custo de substituição em cada contexto, atualizar protocolos e bibliotecas e coordenar com parceiros e fornecedores. Criptografia híbrida — combinar algoritmos clássicos e pós-quânticos em paralelo durante a transição — oferece proteção imediata sem exigir migração completa de uma vez, ao custo de overhead adicional. Para dados que precisam permanecer confidenciais por décadas, a migração é urgente agora, independentemente do prazo estimado para computadores quânticos de escala relevante.

Para hardware e pesquisa quântica, as respostas são de longo prazo e exigem investimento sustentado. Reduzir taxas de erro de qubits físicos é o problema central: sem correção de erros efetiva, computação quântica tolerante a falhas permanece inacessível. Diferentes arquiteturas — qubits supercondutores, íons aprisionados, fótons, spins em silício — têm trade-offs distintos entre coerência, escalabilidade e taxa de erro, e não há consenso sobre qual será dominante. Sistemas híbridos clássico-quânticos, onde computadores quânticos resolvem subproblemas específicos dentro de fluxos computacionais clássicos, são a arquitetura de curto e médio prazo mais realista — e exigem novos modelos de orquestração e abstração que ainda estão sendo desenvolvidos.

Para simulação quântica, onde as aplicações práticas são mais próximas, a resposta é identificar problemas em química computacional, ciência de materiais e otimização onde sistemas quânticos de escala intermediária já oferecem vantagem sobre métodos clássicos, mesmo com erros. Algoritmos variacionais quânticos — como VQE e QAOA — são projetados para sistemas ruidosos atuais e já produzem resultados em problemas de pequena escala. A distância para aplicações industrialmente relevantes ainda é significativa, mas o caminho é mais claro do que para computação quântica tolerante a falhas.

Para formação de recursos humanos, a interdisciplinaridade é condição de viabilidade. Computação quântica exige física quântica, álgebra linear avançada, teoria da informação e ciência da computação simultaneamente — um perfil que currículos tradicionais de nenhuma dessas áreas formam sozinhos. Programas de pós-graduação que integrem física e computação, parcerias com centros internacionais de excelência e atração de pesquisadores com formação híbrida são as respostas disponíveis no curto prazo. Para o Brasil, isso significa também decidir em quais frentes concentrar investimento — pesquisa em hardware quântico exige infraestrutura cara e especializada que poucos países conseguem sustentar, enquanto pesquisa em algoritmos, criptografia pós-quântica e aplicações de simulação tem requisitos mais acessíveis e impacto igualmente relevante.

Para soberania tecnológica, a resposta mais realista para países sem programas quânticos de grande escala é garantir autonomia na camada que protege: criptografia. Depender de algoritmos desenvolvidos e padronizados por outros países não é ideal, mas é menos crítico do que depender de hardware quântico estrangeiro para proteger infraestrutura crítica nacional. Investir em capacidade própria de implementar, auditar e adaptar algoritmos pós-quânticos padronizados — e em pesquisa em criptografia que permita participar dos próximos ciclos de padronização — é uma estratégia de soberania mais acessível do que desenvolver hardware quântico competitivo do zero.

O que atravessa todas essas frentes é uma assimetria de prazo: os riscos chegam antes das oportunidades. A ameaça à criptografia é urgente agora; as aplicações em simulação e otimização são de médio prazo; computação quântica de propósito geral é de longo prazo incerto. Organizações e governos que calibram suas respostas por essa assimetria — priorizando migração criptográfica no curto prazo enquanto investem em formação e pesquisa para o médio e longo prazo — estão melhor posicionados do que aqueles que esperam a ameaça se concretizar para agir.

11. Qual é o impacto da computação quântica na cibersegurança?

A cibersegurança moderna repousa sobre um pressuposto que a computação quântica ameaça diretamente: que certos problemas matemáticos são intratáveis na prática. RSA depende da dificuldade de fatorar inteiros grandes. ECDSA e Diffie-Hellman dependem da dificuldade do logaritmo discreto. Esses problemas não são impossíveis — são apenas difíceis o suficiente para que a melhor solução clássica conhecida demore mais do que a vida útil dos dados protegidos. O algoritmo de Shor muda esse cálculo: num computador quântico de escala suficiente, fatoração e logaritmo discreto se tornam tratáveis em tempo polinomial. A criptografia assimétrica que protege comunicações, autenticações e transações financeiras em toda a internet foi projetada assumindo que esse computador não existiria. Essa suposição está se tornando menos segura.

O problema mais urgente não é o que acontece quando computadores quânticos de grande escala existirem — é o que já está acontecendo agora. O ataque de *harvest now, decrypt later* é simples: adversários com recursos suficientes capturam e armazenam hoje tráfego criptografado com a intenção de decifrá-lo quando a capacidade quântica estiver disponível. Para dados com prazo de sigilo de décadas — segredos de Estado, propriedade intelectual estratégica, registros médicos — isso significa que a proteção precisa ser quântico-resistente agora, não quando os computadores quânticos chegarem. A janela de vulnerabilidade já está aberta.

O algoritmo de Grover afeta criptografia simétrica de forma diferente e mais limitada. Em vez de quebrar, oferece aceleração quadrática em buscas — o que equivale a reduzir à metade o tamanho efetivo de chaves simétricas. AES-128 passa a ter segurança equivalente a AES-64 contra um adversário quântico; AES-256 mantém segurança adequada. A resposta é direta: dobrar o tamanho das chaves simétricas onde necessário. O problema assimétrico não tem solução tão simples.

Distribuição quântica de chaves (QKD) oferece uma abordagem radicalmente diferente: em vez de basear segurança em complexidade computacional, baseia em princípios físicos. Qualquer tentativa de interceptar a troca de chaves perturba o estado quântico de forma detectável, revelando a presença do adversário. A segurança é incondicional — não depende de suposições sobre poder computacional do atacante, presente ou futuro. O problema é infraestrutura: QKD exige canais de comunicação quântica dedicados, sofre perdas com a distância e não escala para redes globais

sem repetidores quânticos que ainda não existem em forma prática. É uma tecnologia promissora para cenários específicos de alta sensibilidade e curta distância, não uma substituição geral para criptografia assimétrica.

A dimensão institucional do problema é significativa. Migrar a infraestrutura criptográfica de uma organização — identificar onde criptografia assimétrica é usada, substituir algoritmos em protocolos, atualizar bibliotecas, renegociar com fornecedores — é um processo que leva anos em organizações de qualquer tamanho. Para infraestruturas críticas nacionais, a coordenação entre governo, indústria e comunidade técnica é condição de viabilidade. E a decisão sobre quais algoritmos adotar não pode ser postergada indefinidamente: o NIST concluiu em 2024 o processo de padronização de algoritmos pós-quânticos, publicando padrões baseados em reticulados. Organizações que ainda não iniciaram o planejamento de migração estão atrasadas.

11.1. Como enfrentar o impacto da computação quântica na cibersegurança?

O impacto da computação quântica na cibersegurança tem duas faces com urgências distintas. A ameaça à criptografia assimétrica é urgente agora, porque harvest now decrypt later significa que dados capturados hoje podem ser decifrados no futuro. As oportunidades em QKD e criptografia quântica são de médio e longo prazo, condicionadas a avanços de infraestrutura que ainda não existem em escala. Confundir os horizontes temporais — tratar tudo como futuro distante ou tudo como crise imediata — produz respostas inadequadas.

A resposta mais concreta e imediata é migração para criptografia pós-quântica. O NIST padronizou em 2024 os primeiros algoritmos resistentes a ataques quânticos: CRYSTALS-Kyber para encapsulamento de chaves e CRYSTALS-Dilithium para assinaturas digitais, ambos baseados em problemas de reticulados considerados difíceis para computadores clássicos e quânticos. A migração não é trivial. O primeiro passo é inventário: mapear onde criptografia assimétrica é usada em sistemas, protocolos, bibliotecas e dependências. O segundo é priorização: sistemas que protegem dados com prazo de sigilo longo precisam migrar antes de sistemas que protegem dados efêmeros. O terceiro é implementação gradual, usando criptografia híbrida — combinar algoritmos clássicos e pós-quânticos em paralelo — para manter proteção durante a transição sem exigir substituição completa de uma vez. O overhead computacional dos algoritmos pós-quânticos é real mas gerenciável na maioria dos contextos; em sistemas embarcados e com recursos limitados, pode exigir otimização adicional.

Para dados já capturados e armazenados por adversários, não há solução retroativa. A única resposta ao harvest now decrypt later é evitar que dados futuros sejam capturados sem proteção quântico-resistente. Isso significa implementar criptografia pós-quântica em canais de comunicação antes que dados sensíveis de longo prazo trafeguem por eles — não depois.

Para QKD, a resposta é realista sobre limitações. A tecnologia é madura o suficiente para implantação em cenários específicos: links de alta segurança entre pontos fixos, como centros de dados governamentais ou instalações militares, onde distância é gerenciável e infraestrutura dedicada é justificável pelo valor dos dados protegidos. Para esses cenários, redes QKD metropolitanas já existem em operação em alguns países. Para redes de longa distância, repetidores quânticos são a peça faltante — e sua viabilidade prática em escala ainda é incerta. Tratar QKD como solução geral é prematuro; tratar como irrelevante é igualmente equivocado.

A coordenação institucional é condição de viabilidade para a transição em escala. Padrões comuns permitem interoperabilidade entre sistemas de diferentes organizações e países — sem eles, cada organização migra para algoritmos diferentes e a infraestrutura fragmenta. O processo de padronização do NIST estabeleceu uma base, mas implementação consistente depende de adoção coordenada por fornecedores de sistemas operacionais, bibliotecas criptográficas, fabricantes de hardware e desenvolvedores de aplicações. Governos têm papel ativo aqui: mandatos de migração para infraestrutura crítica, prazos claros e financiamento para organizações menores sem capacidade técnica própria de migração são instrumentos necessários.

Para o Brasil especificamente, a estratégia mais realista combina adoção dos padrões internacionais com capacidade própria de auditá-los e implementá-los. Desenvolver algoritmos pós-quânticos próprios do zero não é viável nem necessário — participar dos próximos ciclos de padronização internacional com pesquisa em criptografia é mais estratégico. Formar especialistas em criptografia pós-quântica capazes de conduzir a migração de infraestruturas críticas nacionais é urgente e acessível. Depender inteiramente de implementações estrangeiras sem capacidade de auditoria independente é um risco de soberania que a migração pós-quântica, feita corretamente, pode reduzir em vez de ampliar.

12. Qual é o papel da computação na sociedade e quais desafios estão associados?

Computação não é uma tecnologia entre outras. É a infraestrutura sobre a qual a maior parte da organização econômica, social e institucional contemporânea opera. Saúde, educação, finanças, transporte, comunicação, gestão pública — em todos esses setores, sistemas computacionais não apenas suportam processos: eles os constituem. Entender o papel da computação na sociedade exige, portanto, entendê-la como fenômeno sociotécnico — cujos efeitos dependem não apenas das propriedades técnicas dos sistemas, mas de como são projetados, por quem, para quem e em que contexto são implantados.

Essa distinção importa porque os efeitos da computação não são neutros nem uniformes. A mesma plataforma de busca que democratiza acesso à informação também concentra poder sobre o que é encontrável. O mesmo algoritmo de recomendação que personaliza experiências também forma bolhas informacionais e pode ser otimizado para engajamento em vez de veracidade. O mesmo sistema de decisão automatizada que aumenta eficiência em concessão de crédito ou triagem de empregos pode reproduzir e amplificar desigualdades históricas se treinado sobre dados que as refletem. Esses não são efeitos colaterais evitáveis com melhor engenharia — são consequências de escolhas de projeto que têm dimensão política, não apenas técnica.

No Brasil, o papel da computação na sociedade é inseparável da questão da desigualdade. Acesso à infraestrutura digital não é uniforme: diferenças de renda, escolaridade, localização geográfica e deficiência criam barreiras que vão além da ausência de conexão. Acesso significativo — que permite não apenas consumir conteúdo, mas participar, produzir e se beneficiar das oportunidades que a computação cria — é ainda mais desigual. Quando sistemas computacionais tomam decisões sobre acesso a crédito, saúde, educação e serviços públicos, a qualidade e representatividade dos dados sobre os quais operam determina se ampliam ou reproduzem as desigualdades existentes. A computação pode ser vetor de inclusão ou de exclusão — e qual será depende de escolhas que não são técnicas.

Automação e seu impacto no trabalho é outro eixo de tensão sem resolução simples. Sistemas computacionais substituem tarefas rotineiras em velocidade crescente, deslocando ocupações antes estáveis e criando demanda por perfis profissionais que o sistema educacional não forma na velocidade necessária. Isso não é novo — cada onda de automação deslocou trabalho e criou novos tipos de ocupação — mas a velocidade atual e a abrangência dos sistemas de IA tornam o ajuste mais difícil. A questão não é se a automação elimina empregos em agregado, mas como os custos da transição se distribuem — e a evidência histórica sugere que se distribuem de forma desigual, concentrando-se sobre trabalhadores com menos recursos para se requalificar.

Desinformação é o caso em que a computação amplificou um problema existente a ponto de mudar sua natureza. Produzir e distribuir conteúdo falso sempre foi possível; fazê-lo em escala industrial, personalizado para perfis específicos de audiência, com custo próximo de zero e velocidade maior do que qualquer capacidade de verificação, é um problema qualitativamente diferente. Plataformas digitais otimizadas para engajamento descobriram empiricamente que conteúdo que gera raiva e indignação retém atenção melhor do que conteúdo que informa — e otimizaram para isso, com consequências para saúde pública, coesão social e processos democráticos que ainda estão sendo compreendidas.

O impacto ambiental fecha o argumento sobre neutralidade. O crescimento do consumo energético de data centers — projetado para dobrar entre 2022 e 2026, impulsionado principalmente por cargas de IA — é um custo real que não aparece no preço dos serviços digitais e é distribuído de forma desigual: as emissões se concentram onde a infraestrutura está, os benefícios onde o acesso está, e os dois conjuntos não se sobrepõem completamente.

12.1. Como enfrentar os desafios associados ao papel da computação na sociedade?

Enfrentar os desafios associados ao papel da computação na sociedade exige reconhecer que a maioria deles não tem solução técnica — tem solução sociotécnica. Melhor tecnologia é condição necessária mas insuficiente quando os problemas decorrem de escolhas de design, incentivos econômicos e estruturas de poder que a tecnologia sozinha não altera. As respostas precisam operar simultaneamente em múltiplas camadas: técnica, regulatória, educacional e de governança.

Para inclusão digital, a resposta mais direta é infraestrutura — e o documento da SBC é explícito sobre isso ao tratar acesso universal à Internet como um dos seis Grandes Desafios para 2025–2035. Conectividade de qualidade em regiões remotas e periféricas, custo acessível de dispositivos e planos de dados, e letramento digital que vai além de uso básico são condições de acesso significativo, não apenas de acesso formal. Mas infraestrutura não resolve o problema de representatividade: sistemas que tomam decisões sobre populações sub-representadas nos dados sobre os quais foram treinados reproduzem e amplificam desigualdades independentemente de quão boa seja a conexão das populações afetadas. Isso exige que produção de dados representativos e desenvolvimento de sistemas com participação das comunidades afetadas sejam tratados como requisitos, não como complementos opcionais.

Para desinformação, não há solução que não envolva trade-offs entre valores que competem. Moderação de conteúdo em escala exige automação, e automação comete erros que afetam desproporcionalmente grupos já marginalizados. Algoritmos de recomendação otimizados para qualidade informacional em vez de engajamento reduzem tempo de uso — o que conflita com o modelo de negócio das plataformas. Regulação de plataformas envolve questões de liberdade de expressão que diferentes sociedades resolvem de formas diferentes. As respostas disponíveis — verificação de fatos em escala com apoio de IA, transparência sobre como algoritmos de recomendação funcionam, responsabilização legal de plataformas por danos causados por conteúdo que amplificam — são parciais e sujeitas a controvérsia. O que não é aceitável é tratar o problema como inevitável ou como responsabilidade exclusiva do usuário individual.

Para automação e trabalho, as respostas são distributivas antes de serem técnicas. A questão não é impedir automação — é garantir que seus benefícios sejam distribuídos de forma que os custos da transição não recaiam inteiramente sobre quem menos tem condições de absorvê-los. Isso envolve investimento em requalificação profissional em áreas com alto risco de deslocamento, proteção social para trabalhadores em transição e redesenho de sistemas educacionais para formar perfis que combinem competências técnicas e humanas que a automação não replica facilmente. Nenhuma dessas respostas é simples ou barata — e todas exigem decisões políticas que vão além do que a computação pode oferecer.

Para ética e governança de sistemas computacionais com impacto social, as respostas combinam regulação, transparência e responsabilização. Avaliações de impacto algorítmico — análises formais dos efeitos de sistemas automatizados sobre diferentes grupos antes da implantação — são o equivalente computacional de estudos de impacto ambiental: custosos e imperfeitos, mas melhores do que descobrir os danos depois. Direito a explicação em decisões automatizadas de alto impacto — previsto na LGPD mas ainda sem detalhamento operacional suficiente — é condição de contestabilidade, que é condição de responsabilização. Auditoria independente de sistemas que afetam direitos é condição de confiança. Nenhum desses mecanismos funciona sem capacidade técnica de implementá-los — o que conecta governança à formação de recursos humanos.

Para impacto ambiental, as respostas técnicas existem — algoritmos energeticamente eficientes, hardware especializado, escalonamento dinâmico, infraestrutura alimentada por renováveis — mas dependem de que eficiência

energética seja tratada como critério de projeto, não como otimização posterior. O documento da SBC identifica computação sustentável como um dos Grandes Desafios exatamente porque a trajetória atual de crescimento do consumo energético da computação é insustentável, e mudar essa trajetória exige mudanças de prática que a comunidade de computação ainda não consolidou.

O que atravessa todas essas frentes é uma tensão que não tem resolução técnica: computação é simultaneamente instrumento de emancipação e instrumento de controle, de inclusão e de exclusão, de eficiência e de concentração de poder. Qual dessas faces prevalece em cada contexto depende de escolhas — sobre quem participa do design, quais objetivos são otimizados, quem responde pelos danos, quem se beneficia dos ganhos. Essas são escolhas políticas, e tratá-las como questões técnicas é uma forma de ocultar sua natureza.

13. Quais são os principais desafios de escalabilidade e infraestrutura na computação moderna?

Escalar um sistema é fácil quando tudo funciona. O desafio real aparece quando partes falham — e em sistemas distribuídos de larga escala, partes sempre falham. Servidores travam, redes partem, discos corrompem. A questão não é se haverá falhas, mas como o sistema se comporta quando elas ocorrem. Projetar para falha, não para ausência de falha, é o princípio que separa sistemas que escalam dos que colapsam.

O resultado teórico que estrutura os limites de sistemas distribuídos é o teorema CAP: consistência, disponibilidade e tolerância a partições de rede não podem ser garantidas simultaneamente. Na presença de uma partição — quando nós de um sistema distribuído perdem comunicação entre si — o sistema precisa escolher entre continuar respondendo com dados potencialmente desatualizados (disponibilidade) ou parar de responder até a consistência ser restaurada (consistência). Não há como ter os dois. Essa não é uma limitação de implementação — é um resultado matemático sobre o que é possível. Toda decisão de arquitetura em sistemas distribuídos de larga escala é, em algum nível, uma instanciação dessa escolha. Bancos de dados que escolhem consistência forte — como sistemas transacionais financeiros — pagam com latência e disponibilidade reduzida. Sistemas que escolhem disponibilidade — como DNS, redes de distribuição de conteúdo e muitas aplicações web de larga escala — aceitam consistência eventual, onde diferentes nós podem temporariamente divergir antes de convergir para um estado consistente.

Gestão de recursos em infraestrutura moderna adicionou uma camada de complexidade que antes não existia: contêineres e orquestração. Sistemas como Kubernetes permitem empacotar aplicações com suas dependências e distribuí-las dinamicamente por clusters de máquinas, escalonando para cima ou para baixo conforme demanda. A abstração é poderosa — o desenvolvedor declara o estado desejado e o sistema tenta mantê-lo — mas a complexidade não desaparece, ela se desloca. Depurar comportamento emergente em um cluster com centenas de serviços interagindo é um problema qualitatively diferente de depurar uma aplicação monolítica. Falhas se tornam mais raras mas mais difíceis de diagnosticar.

A proliferação de dispositivos IoT e aplicações sensíveis a latência criou pressão para mover processamento para fora da nuvem centralizada. A razão não é apenas latência — é volume e física. Um carro autônomo não pode esperar ida e volta de requisição para uma nuvem centralizada antes de decidir frear. Uma fábrica com milhares de sensores não pode enviar todos os dados brutos para processamento remoto sem saturar a rede. Edge e fog computing movem processamento para próximo da fonte dos dados, mas ao custo de fragmentar a infraestrutura: em vez de gerenciar um data center, é preciso gerenciar centenas ou milhares de nós distribuídos fisicamente, com conectividade intermitente, em ambientes que não são data centers. Atualizar software, garantir segurança e manter consistência nesse ambiente é substancialmente mais difícil.

A demanda por computação intensiva — especialmente treinamento e inferência de modelos de IA de grande escala — acelerou a especialização de hardware de formas que remodelam a infraestrutura. GPUs, TPUs e aceleradores customizados oferecem ganhos de desempenho por watt que CPUs de propósito geral não conseguem competir para cargas específicas, mas introduzem heterogeneidade que complica orquestração e otimização. Pilhas de software precisam extrair eficiência de hardware cada vez mais especializado enquanto mantêm portabilidade — uma tensão que frameworks como CUDA, ROCm e compiladores de ML tentam resolver sem eliminar completamente.

Sustentabilidade é onde a escala torna o problema visível de forma mais brutal. Estimativas atuais indicam que data centers consomem entre 1% e 2% da demanda global de energia elétrica, com projeções de crescimento acelerado impulsionado principalmente por cargas de IA. Para o Brasil, que pode ser incapaz de expandir geração e distribuição de energia na velocidade que o crescimento da computação demandaria, isso não é problema abstrato — é restrição concreta ao desenvolvimento tecnológico soberano. O consumo energético de um único treinamento de modelo de linguagem de grande escala pode superar o consumo anual de centenas de residências, e o número de treinamentos realizados globalmente cresce sem que essa conta apareça explicitamente em nenhum produto.

13.1. Como enfrentar os desafios de escalabilidade e infraestrutura na computação moderna?

As respostas aos desafios de escalabilidade e infraestrutura não eliminam as tensões fundamentais — elas as tornam gerenciáveis dentro de restrições específicas. O teorema CAP não tem solução de engenharia; tem trade-offs que precisam ser escolhidos conscientemente de acordo com os requisitos de cada sistema. O princípio organizador é o mesmo das outras áreas: entender os limites teóricos antes de escolher a arquitetura, não descobri-los em produção.

Para consistência e disponibilidade em sistemas distribuídos, a resposta moderna é consistência eventual bem especificada — não como concessão, mas como escolha deliberada com garantias claras. Sistemas como DynamoDB, Cassandra e Riak constroem sobre modelos de consistência eventual com operações CRDT (*Conflict-free Replicated Data Types*), estruturas de dados projetadas para que conflitos de atualização concorrente possam ser resolvidos deterministicamente sem coordenação global. Para sistemas que precisam de consistência forte, Spanner e CockroachDB usam relógios sincronizados e consenso distribuído (Paxos, Raft) para oferecer transações distribuídas com

garantias ACID, ao custo de latência adicional proporcional à distância geográfica entre réplicas. A escolha entre esses modelos não é técnica no vácuo — depende do que o sistema pode tolerar: um banco financeiro tolera latência mas não inconsistência; uma rede de distribuição de conteúdo tolera dados ligeiramente desatualizados mas não indisponibilidade.

Para tolerância a falhas e resiliência, a abordagem mais eficaz é projetar para falha desde o início, não adicionar resiliência depois. Isso significa redundância em múltiplos níveis — réplicas de dados, instâncias de serviço, zonas de disponibilidade geográficas —, circuit breakers que isolam componentes com falha antes que propaguem erros, e estratégias de degradação graciosa que mantêm funcionalidade parcial quando subsistemas falham. Chaos engineering — injetar falhas deliberadas em produção para descobrir pontos de fragilidade antes que ocorram naturalmente — tornou-se prática padrão em organizações que operam em escala. A premissa é que sistemas que nunca foram testados em falha não são sistemas confiáveis; são sistemas cuja falha ainda não foi observada.

Para gestão de recursos e orquestração, Kubernetes tornou-se o padrão de fato para implantação de aplicações em contêineres, mas a complexidade de operar clusters Kubernetes em escala gerou uma indústria inteira de ferramentas de observabilidade, depuração e automação. O problema não é a tecnologia em si — é que a abstração que Kubernetes oferece esconde complexidade em vez de eliminá-la, e essa complexidade aparece em momentos de falha. Mesh de serviços como Istio e Linkerd adicionam gerenciamento de tráfego, observabilidade e segurança na camada de comunicação entre serviços, tornando o comportamento do sistema mais visível e controlável sem exigir que cada serviço implemente essas preocupações individualmente.

Para edge computing, a resposta é federação e autonomia local. Dispositivos de borda precisam operar com conectividade intermitente, o que exige capacidade de tomada de decisão local e sincronização assíncrona quando a conexão é restaurada. Protocolos de sincronização que toleram conflitos e divergência temporária — extensões dos mesmos modelos de consistência eventual usados em sistemas distribuídos centralizados — são a base técnica. A dificuldade operacional de gerenciar firmware, certificados de segurança e configuração em frota distribuída de dispositivos físicos ainda é um problema parcialmente em aberto, especialmente em escala de IoT industrial.

Para sustentabilidade de infraestrutura, as respostas técnicas mais maduras são eficiência algorítmica, hardware especializado e fontes renováveis. Do lado algorítmico, técnicas como quantização, destilação de modelos e poda reduzem custo computacional de inferência sem perda proporcional de desempenho. Do lado de hardware, aceleradores especializados oferecem desempenho por watt muito superior a CPUs de propósito geral para cargas específicas. Do lado de energia, data centers alimentados por renováveis — com acordos de compra de energia de longo prazo que garantem adicionalidade, não apenas compensação — são a direção que grandes operadores estão tomando, mas que depende de disponibilidade e custo de renováveis em cada região. Para o Brasil, que tem matriz elétrica com alta participação de renováveis, isso é uma vantagem comparativa concreta para hospedar infraestrutura computacional sustentável — se o investimento em infraestrutura de transmissão e conectividade acompanhar.

O que atravessa todas essas respostas é uma lição que a engenharia de sistemas distribuídos aprendeu empiricamente: sistemas simples falham de formas simples; sistemas complexos falham de formas que ninguém antecipou. A pressão por escalabilidade empurra sistemas para complexidade crescente, e complexidade crescente empurra probabilidade de comportamento emergente inesperado. As organizações mais bem-sucedidas em operar infraestrutura em escala não são necessariamente as que usam a tecnologia mais sofisticada — são as que mantêm simplicidade onde possível, investem em observabilidade para entender o que seus sistemas estão fazendo, e constroem cultura de aprendizado com falhas em vez de cultura de evitação de falhas.

14. Quais são os desafios ambientais da computação moderna?

Computação tem um custo físico que raramente aparece na conta. Cada busca, cada mensagem, cada modelo treinado consome energia — e essa energia vem de algum lugar, com emissões que vão para algum lugar. O crescimento do setor tornou esse custo difícil de ignorar: estimativas recentes situam o consumo de data centers entre 1% e 2% da demanda global de energia elétrica, com projeções indicando que pode dobrar até 2026 — um crescimento equivalente a adicionar ao sistema elétrico global uma demanda da ordem da Suécia ou da Alemanha. O principal motor desse crescimento é IA: treinar um único modelo de linguagem de grande escala pode consumir energia equivalente ao consumo anual de centenas de residências, e o número de treinamentos realizados globalmente cresce sem que esse custo apareça explicitamente em nenhum produto.

Eficiência energética melhorou consistentemente nas últimas décadas — processadores fazem mais operações por watt do que faziam há dez anos, data centers operam com PUE (*Power Usage Effectiveness*) muito menor do que na geração anterior. O problema é o paradoxo de Jevons: ganhos de eficiência tendem a ser consumidos por aumento de demanda, resultando em consumo total maior, não menor. Computação mais barata por operação significa mais operações realizadas. Isso não invalida investimento em eficiência — sem ele, o crescimento seria ainda mais insustentável — mas significa que eficiência sozinha não resolve o problema de escala.

Resfriamento é uma dimensão frequentemente omitida. Data centers geram calor proporcional ao processamento, e dissipar esse calor consome recursos adicionais. Sistemas de resfriamento evaporativo usam água em quantidade significativa — estimativas para grandes data centers chegam a milhões de litros por dia. Em regiões com estresse hídrico, isso cria conflito real com outros usos: agricultura, abastecimento humano, ecossistemas. A localização geográfica de data centers não é decisão neutra do ponto de vista ambiental.

O ciclo de vida dos equipamentos adiciona dimensões que o foco em energia elétrica tende a obscurecer. Fabricar semicondutores exige minerais raros — lítio, cobalto, terras raras — extraídos com impacto ambiental e social significativo, frequentemente em regiões com regulação ambiental fraca. A fabricação de um único chip moderno usa quantidades relevantes de água ultrapura e produtos químicos. E o descarte: resíduos eletrônicos crescem mais

rápido do que qualquer outra categoria de lixo, com taxas de reciclagem formal ainda baixas e grande parte sendo processada informalmente em condições que expõem trabalhadores e ecossistemas a substâncias tóxicas. A narrativa de que computação é uma indústria limpa porque não tem chaminés visíveis omite essa parte da cadeia.

Para o Brasil, a dimensão ambiental da computação tem uma especificidade que o documento da SBC identifica como risco de soberania. O país pode ser incapaz de expandir geração e distribuição de energia na velocidade que o crescimento da infraestrutura computacional demandaria, o que limitaria capacidade de processamento local e ampliaria dependência de infraestrutura estrangeira. Ao mesmo tempo, a matriz elétrica brasileira com alta participação de renováveis é uma vantagem comparativa concreta para hospedar infraestrutura computacional com menor pegada de carbono — se o investimento em conectividade e infraestrutura de transmissão acompanhar.

14.1. Como enfrentar os desafios ambientais da computação moderna?

Enfrentar os desafios ambientais da computação exige atuar em múltiplas camadas simultaneamente, porque o problema tem múltiplas origens. Eficiência de hardware, eficiência de software, escolha de fontes de energia e governança do crescimento da demanda são frentes distintas com respostas distintas — e nenhuma delas, isolada, resolve o problema.

No plano do hardware, aceleradores especializados — GPUs, TPUs e chips de inferência customizados — oferecem desempenho por watt muito superior a CPUs de propósito geral para cargas específicas como treinamento e inferência de modelos de IA. A especialização tem custo: fragmenta o ecossistema de software e cria dependência de poucos fornecedores. Mas o ganho de eficiência energética para as cargas mais intensivas é suficientemente grande para justificar a complexidade adicional. Resfriamento líquido direto — que conduz calor de forma muito mais eficiente do que ar — permite densidades de processamento maiores com menos energia de resfriamento, e está se tornando padrão em data centers de nova geração. Localização geográfica estratégica de data centers — próximos a fontes de energia renovável abundante, em climas que reduzem necessidade de resfriamento ativo, com acesso a água — é uma decisão de infraestrutura com impacto ambiental concreto.

No plano do software, a resposta mais estrutural é tratar eficiência energética como critério de projeto desde o início, não como otimização posterior. Isso exige métricas — energia por operação, emissões por inferência — que a comunidade ainda não consolidou como padrão. Técnicas como quantização (reduzir precisão numérica de pesos de modelos), destilação (treinar modelos menores que imitam modelos maiores) e poda (remover parâmetros com contribuição marginal) reduzem custo computacional de inferência com perda de desempenho geralmente aceitável para a maioria das aplicações. Para treinamento, checkpointing eficiente e estratégias de early stopping evitam repetir computação desnecessária. O movimento de *data-centric AI* contribui aqui também: dados de melhor qualidade permitem modelos menores com desempenho equivalente.

Para energia, a transição para renováveis é condição necessária mas não suficiente. Acordos de compra de energia que garantem adicionalidade — que a energia renovável comprada representa geração nova, não redirecionamento de geração existente — são mais eficazes do que compensação de carbono via créditos. Para o Brasil, com matriz já predominantemente renovável, o desafio é garantir que o crescimento da demanda computacional seja atendido por expansão de renováveis, não por acionamento de termelétricas na margem. Isso exige planejamento setorial que trate infraestrutura computacional como parte da política energética, não como demanda residual.

O ciclo de vida dos equipamentos exige respostas que vão além da operação dos data centers. Design para durabilidade e reparabilidade — em vez de obsolescência planejada — reduz a frequência de substituição. Programas de reuso e remanufatura de equipamentos extendem vida útil. Reciclagem formal com rastreabilidade — que garante que minerais recuperados retornam à cadeia produtiva e que resíduos tóxicos são tratados adequadamente — é condição de responsabilidade que a regulação ainda não exige de forma consistente.

Para o paradoxo de Jevons, não há solução técnica — é um problema de governança. Eficiência que não é acompanhada de limites ao crescimento da demanda resulta em consumo total maior. Isso exige instrumentos que tornem o custo ambiental da computação visível e que criem incentivos para reduzi-lo: relatórios obrigatórios de emissões para operadores de data centers, métricas de sustentabilidade em processos de procurement público, e inclusão de custo energético em avaliações de impacto de sistemas de IA. O documento da SBC aponta nessa direção ao recomendar que iniciativas de governança ESG no setor produtivo incluam a redução do impacto ambiental da computação como critério explícito.

A constatação mais incômoda é que as ferramentas técnicas para reduzir o impacto ambiental da computação existem e são conhecidas. O que falta é que eficiência energética seja tratada como requisito de negócio com o mesmo peso que desempenho e custo — e isso depende de regulação, cultura organizacional e métricas que tornem o custo ambiental visível para quem toma as decisões de projeto.

15. Como definir uma agenda de pesquisa relevante em computação atualmente?

Definir uma agenda de pesquisa relevante em computação é mais difícil do que parece, e a dificuldade não é técnica. O campo tem problemas em abundância — o que falta é critério para escolher entre eles. Esse critério depende de onde se está, com quais recursos, para qual comunidade e com qual horizonte temporal. Uma agenda relevante para um grupo de pesquisa no MIT não é necessariamente relevante para um grupo no Brasil, e vice-versa. O documento da SBC que estrutura os Grandes Desafios da Computação para 2025–2035 é precisamente um exercício coletivo de responder a essa pergunta num contexto específico — e entender como ele foi construído é tão importante quanto conhecer seu conteúdo.

A primeira tensão que qualquer agenda de pesquisa precisa resolver é entre pesquisa fundamental e pesquisa aplicada. Pesquisa fundamental produz conhecimento que amplia o que é possível — novos modelos, novos algoritmos, novos

resultados teóricos. Pesquisa aplicada resolve problemas concretos com técnicas existentes. As duas são necessárias e as duas têm valor, mas têm ciclos de tempo, critérios de publicação e fontes de financiamento diferentes. Agendas que tentam ser as duas coisas simultaneamente frequentemente não são nenhuma. A escolha não é entre rigor e relevância — pesquisa fundamental pode ser altamente relevante, e pesquisa aplicada pode ser rigorosa. A escolha é sobre qual pergunta está sendo feita: o que é possível, ou como fazer o que já sabemos que é possível funcionar em condições reais.

A segunda tensão é entre problemas tratáveis e problemas importantes. Os problemas mais importantes raramente são os mais tratáveis — são os mais difíceis, com dados mais escassos, métricas mais contestadas e soluções mais distantes. Problemas tratáveis produzem publicações; problemas importantes produzem impacto. A pressão por publicação em conferências e periódicos de alto impacto cria incentivos para trabalhar em variações incrementais de problemas bem definidos, em vez de problemas novos onde o risco de não publicar é alto. Reconhecer essa pressão não é suficiente para resistir a ela, mas é condição para fazê-lo conscientemente.

No contexto brasileiro, a tensão entre agenda nacional e agenda internacional é particularmente relevante. A comunidade de computação brasileira publica em veículos internacionais, treina nos mesmos benchmarks, compete pelos mesmos prêmios. Isso é bom — integração com a fronteira do conhecimento global é condição de qualidade. Mas cria uma pressão para trabalhar em problemas que a comunidade internacional considera interessantes, que nem sempre são os problemas que o Brasil precisa resolver. Dados sobre a realidade brasileira — suas línguas, suas desigualdades específicas, sua diversidade regional, sua infraestrutura — raramente são os dados sobre os quais os grandes modelos foram treinados ou os grandes benchmarks foram construídos. Uma agenda de pesquisa relevante para o Brasil precisa incluir a produção de conhecimento sobre problemas brasileiros, não apenas a aplicação de soluções desenvolvidas em outros contextos.

Os Grandes Desafios da SBC para 2025–2035 oferecem um mapa concreto dessas prioridades nacionais: IA responsável e seus desafios de dados, algoritmos e governança; cibersegurança com déficit estimado de centenas de milhares de profissionais; computação quântica e seus impactos na criptografia; acesso universal e significativo à internet; computação sustentável com crescimento de consumo energético insustentável; e ecossistemas computacionais éticos e inclusivos. Cada um desses eixos define uma classe de problemas onde pesquisa brasileira tem tanto necessidade quanto potencial de contribuição própria. A escolha de qual eixo priorizar depende de competências existentes, recursos disponíveis e onde a contribuição marginal é maior.

Interdisciplinaridade é condição de relevância em muitos desses eixos, não diferencial opcional. Problemas de IA responsável não têm solução puramente computacional — exigem juristas, filósofos, cientistas sociais. Problemas de acesso universal envolvem economia, políticas públicas e ciências sociais tanto quanto redes e sistemas. Problemas de sustentabilidade conectam computação a ciências ambientais e engenharia de energia. Isso tem implicações práticas para como grupos de pesquisa são formados, como projetos são financiados e como resultados são avaliados — e a estrutura institucional das universidades brasileiras ainda não está bem adaptada para pesquisa genuinamente interdisciplinar.

Por fim, uma agenda de pesquisa precisa ser honesta sobre viabilidade. Problemas importantes para os quais não há dados, infraestrutura, financiamento ou massa crítica de pesquisadores produzem projetos que não chegam a lugar algum. A viabilidade não é critério de segundo nível — é condição de que a pesquisa seja feita. Isso significa identificar onde os recursos existentes permitem contribuição real, construir infraestrutura onde ela falta, e colaborar onde a contribuição individual é insuficiente. O Brasil tem vantagens comparativas reais em alguns domínios — biodiversidade, diversidade linguística e cultural, escala de alguns problemas sociais que existem aqui em forma que não existe em países de renda alta — e uma agenda de pesquisa inteligente as reconhece em vez de ignorá-las.

15.1. Como construir e sustentar uma agenda de pesquisa relevante em computação no Brasil?

Construir uma agenda de pesquisa relevante é mais fácil do que sustentá-la. A construção é um exercício intelectual — identificar problemas importantes, avaliar viabilidade, posicionar em relação à literatura. A sustentação envolve financiamento, formação de equipe, publicação, colaboração e navegação de incentivos institucionais que frequentemente apontam em direção diferente da relevância. As respostas a essa pergunta precisam ser honestas sobre essa distinção.

Para identificação de problemas, o ponto de partida mais produtivo não é a literatura internacional — é o problema concreto. Questões que emergem de contextos reais de aplicação têm duas vantagens sobre questões identificadas por revisão de literatura: tendem a ser genuinamente difíceis de formas que a literatura não antecipou, e constroem pontes com setores que têm dados, recursos e interesse em soluções. Para o Brasil, isso significa engajamento com governo, setor de saúde, agricultura, educação e outros domínios onde computação pode contribuir de forma que pesquisa internacional não resolve diretamente. O risco é perder rigor ao trabalhar em problemas de engenharia disfarçados de pesquisa; a resposta é garantir que a contribuição seja de conhecimento novo, não apenas de aplicação de técnicas existentes.

Para financiamento, a realidade do Brasil em 2025 é que recursos para pesquisa são escassos e disputados. Editais do CNPq e da FAPESP financiam pesquisa de qualidade, mas com ciclos longos e incerteza de renovação que dificultam planejamento de longo prazo. Parcerias com setor produtivo oferecem recursos mais estáveis mas com restrições sobre publicação e propriedade intelectual que precisam ser negociadas explicitamente. Colaborações internacionais abrem acesso a financiamento de agências como NSF e EU Horizon, mas exigem parceiros estabelecidos e frequentemente favorecem agendas definidas externamente. Uma estratégia de financiamento diversificada — que combine fontes nacionais, internacionais e privadas — é mais resiliente do que dependência de uma única fonte, mas exige gestão que muitos grupos acadêmicos não têm estrutura para fazer.

Para formação de equipe, a escassez de doutores qualificados em computação no Brasil é um gargalo real. Atrair e reter pesquisadores enfrenta competição com a indústria, que oferece salários incompatíveis com a carreira acadêmica para os mesmos perfis. Iniciação científica bem estruturada, mestrado focado em pesquisa e doutorado com orientação próxima são a base — mas dependem de que o orientador tenha tempo e recursos para dedicar à formação, o que a sobrecarga administrativa de universidades públicas frequentemente compromete. Colaborações internacionais para doutorado sanduíche e pós-doutorado no exterior aceleram formação e ampliam redes, mas criam risco de fuga de talentos se a estrutura de retorno não for atrativa.

Para publicação e posicionamento, a tensão entre quantidade e qualidade é real e tem consequências para progressão na carreira. Publicar em veículos de alto impacto exige trabalho em problemas que a comunidade internacional reconhece como relevantes, o que pode não coincidir com problemas relevantes para o Brasil. Uma estratégia equilibrada publica em veículos internacionais de primeira linha os resultados com contribuição teórica mais clara, e em veículos nacionais e de aplicação os resultados com contribuição mais contextual. O erro é tratar as duas como substitutas — são complementares e respondem a comunidades diferentes.

Para colaboração, redes de pesquisa nacionais e internacionais são multiplicadores de capacidade. A SBC e seus eventos estruturam uma comunidade nacional que compartilha problemas, dados e infraestrutura. Colaborações internacionais com grupos que têm infraestrutura e dados que o Brasil não tem — acesso a supercomputadores, grandes conjuntos de dados rotulados, equipamentos experimentais — compensam limitações locais. O que não funciona é colaboração assimétrica onde o grupo brasileiro fornece dados e o grupo estrangeiro faz a pesquisa — isso produz publicações conjuntas mas não constrói capacidade local.

O que atravessa todas essas dimensões é uma escolha que cada pesquisador e cada grupo precisa fazer explicitamente: para qual comunidade se está pesquisando. Pesquisa para a comunidade internacional de computação tem critérios, veículos e recompensas específicos. Pesquisa para resolver problemas brasileiros tem critérios, parceiros e impactos diferentes. As duas não são incompatíveis, mas exigem estratégias distintas — e tentar fazer as duas sem reconhecer a distinção frequentemente resulta em fazer nenhuma com excelência.

16. Quais são os desafios do acesso universal e significativo à Internet no Brasil?

Acesso universal à Internet e acesso significativo à Internet são coisas diferentes — e a distinção define onde está o problema real. Cobertura formal, medida como porcentagem da população dentro do alcance de uma rede, melhorou consistentemente no Brasil. Mas cobertura não é uso, e uso não é benefício. Uma família com conexão 3G instável em região remota, cujo plano de dados é consumido em poucos vídeos, que usa dispositivo compartilhado com tela quebrada, que não tem letramento digital para navegar além de redes sociais, e que não encontra conteúdo relevante em sua língua ou formato — essa família tem acesso formal e não tem acesso significativo. O desafio real é fechar essa distância, e ela é maior e mais estrutural do que indicadores de cobertura sugerem.

O Brasil continental torna esse problema especialmente difícil porque não há uma solução. Amazônia, sertão nordestino, zona costeira, periferias urbanas e regiões metropolitanas têm desafios de infraestrutura tão distintos que exigem tecnologias distintas. Fibra óptica é a solução de maior capacidade mas economicamente inviável em regiões de baixa densidade populacional. Satélites de órbita baixa — como Starlink — chegam onde fibra não chega, mas com custo de equipamento e assinatura que exclui populações de baixa renda sem subsídio. Redes de rádio e mesh são mais baratas por ponto de cobertura mas com capacidade limitada. Nenhuma tecnologia resolve o problema sozinha; o desafio é combinar o mix adequado para cada contexto e garantir que quem menos tem recursos seja alcançado por quem tem menor custo, não deixado para solução residual.

A escalabilidade da infraestrutura tem uma dimensão específica que o documento da SBC identifica como subdesafio: implementar sensores como plataforma para aplicações nacionais em extensas áreas geográficas. O Brasil tem problemas de monitoramento ambiental, agrícola, climático e de infraestrutura que operam em escala continental — desmatamento na Amazônia, seca no semiárido, enchentes no Sul, pragas agrícolas no Cerrado. Redes de sensores IoT distribuídas por essas extensões exigem infraestrutura de comunicação que funcione em condições hostis, com energia limitada, com conectividade intermitente e com volumes de dados que precisam ser processados próximos à fonte porque não há largura de banda para enviar tudo para a nuvem. Esse é um problema de pesquisa genuíno com aplicação imediata e específica ao contexto brasileiro.

Resiliência climática é outro eixo onde a especificidade brasileira é concreta. Eventos climáticos extremos com frequência crescente — enchentes no Sul que destroem postes e cabos, secas que afetam operação de data centers dependentes de água para resfriamento, queimadas que isolam regiões inteiras — comprometem infraestrutura de comunicação exatamente quando ela é mais necessária: em situações de emergência. Infraestrutura resiliente exige redundância de caminhos, capacidade de operação com energia alternativa, mecanismos de recuperação rápida e, em alguns casos, infraestrutura de emergência pré-posicionada. Isso não é opcional num país com o perfil climático e geográfico do Brasil.

Segurança e privacidade na expansão da conectividade criam um problema específico: quanto mais pessoas com menos letramento digital se conectam, maior a superfície de ataque e menor a capacidade de defesa individual. Golpes por WhatsApp, phishing por SMS, fraudes em aplicativos de pagamento — esses vetores afetam desproporcionalmente populações que acabaram de se conectar, que têm menos familiaridade com os riscos e menos recursos para se recuperar de danos financeiros. Expandir acesso sem expandir simultaneamente capacidade de proteção amplifica vulnerabilidade em vez de reduzir exclusão.

A dimensão de usabilidade e acessibilidade fecha o argumento sobre o que significa acesso significativo. Pessoas com deficiência visual, auditiva ou motora enfrentam barreiras que infraestrutura física não resolve. Populações com baixa escolaridade precisam de interfaces que não pressuponham letramento avançado. Comunidades indígenas e

quilombolas precisam de conteúdo em suas línguas e formas culturais. O acesso universal em sentido pleno exige que a infraestrutura seja condição necessária, não suficiente — e que o que é acessível através dela seja relevante para quem está sendo conectado.

16.1. Como enfrentar os desafios do acesso universal e significativo à Internet no Brasil?

Enfrentar os desafios de acesso universal e significativo à Internet no Brasil exige aceitar que o problema tem camadas que respostas técnicas sozinhas não resolvem. Infraestrutura é condição necessária; não é suficiente. As respostas precisam operar simultaneamente em conectividade, custo, letramento, conteúdo e proteção — e precisam chegar onde o mercado não chega por conta própria, porque as populações mais desconectadas são as menos rentáveis para operadores privados.

Para infraestrutura em regiões remotas e de baixa densidade, a resposta é mix tecnológico subsidiado. Satélites LEO como Starlink chegam onde fibra não chegará no horizonte de planejamento relevante, mas o custo de equipamento e assinatura os torna inacessíveis sem subsídio direto. O modelo mais promissor combina financiamento público para equipamento comunitário — um ponto de acesso compartilhado por uma comunidade, em vez de assinatura individual — com regulação que obriga operadores com espectro licenciado a cumprir metas de cobertura em áreas não rentáveis como contrapartida. O Fundo de Universalização dos Serviços de Telecomunicações (FUST) existe para esse fim e tem sido subutilizado; reformar seus critérios de alocação é mais urgente do que criar novos instrumentos.

Para IoT e sensoriamento em escala nacional, a resposta é infraestrutura de dados como bem público. Redes de sensores para monitoramento ambiental, agrícola e climático têm externalidades positivas que justificam investimento público — o benefício de monitorar desmatamento ou prever enchentes não é capturado por quem instala os sensores. Protocolos de comunicação de baixo consumo energético como LoRaWAN e NB-IoT permitem conectividade em áreas sem infraestrutura celular convencional, com bateria de longa duração. Processamento de borda reduz a dependência de backhaul para análise de dados. O desafio é governança dos dados coletados — quem tem acesso, em que condições, com quais garantias de privacidade para comunidades monitoradas.

Para resiliência climática, as respostas combinam redundância de infraestrutura com protocolos de emergência. Múltiplos caminhos de conectividade — fibra mais rádio mais satélite — garantem que falha em um não isola a região. Infraestrutura de comunicação de emergência pré-posicionada em regiões de alto risco climático — rádios satelitais, geradores, repetidores portáteis — permite comunicação mínima mesmo com infraestrutura principal comprometida. Acordos entre operadoras para compartilhamento de infraestrutura em emergências reduzem o tempo de recuperação. Nenhuma dessas respostas é cara em relação ao custo de ficar isolado durante uma emergência.

Para custo de acesso, a resposta mais direta é regulação de preços em mercados com poder de mercado concentrado e subsídio direto para populações de baixa renda. O Brasil tem mercado de telecomunicações altamente concentrado em algumas operadoras, com pouca pressão competitiva em regiões remotas. Regulação que separa infraestrutura de serviço — obrigando compartilhamento de infraestrutura entre operadoras — pode aumentar competição sem duplicar investimento. Programas de subsídio de conectividade para famílias de baixa renda, vinculados a programas sociais existentes, são mais eficazes do que subsídio à oferta sem garantia de que chega a quem precisa.

Para letramento digital e conteúdo relevante, as respostas são educacionais e culturais antes de serem técnicas. Programas de alfabetização digital que ensinam não apenas como usar dispositivos mas como avaliar informação, proteger privacidade e aproveitar oportunidades digitais precisam ser integrados à educação básica e a programas de educação de adultos. Conteúdo em línguas indígenas e em formatos acessíveis para pessoas com deficiência exige investimento público — o mercado não produz espontaneamente conteúdo para mercados pequenos e de baixa renda. Aplicações de governo eletrônico, saúde e educação em português claro e interface simples reduzem a barreira de entrada para populações com baixa escolaridade.

Para proteção de populações recém-conectadas, a resposta combina educação, design e regulação. Educação sobre golpes e fraudes digitais precisa chegar junto com o acesso, não depois. Design de aplicações que tornam comportamento seguro o padrão — autenticação em dois fatores ativada por padrão, alertas claros antes de transações financeiras — reduz dependência de que o usuário identifique o risco. Regulação que responsabiliza plataformas e operadoras por danos causados a usuários vulneráveis cria incentivos para que a proteção seja incorporada ao produto, não deixada como responsabilidade do usuário.

O que atravessa todas essas frentes é uma constatação que o mercado não resolve sozinho: as populações mais desconectadas são as que têm menos poder de compra, vivem em regiões menos rentáveis e têm menos capacidade de se proteger quando conectadas. Isso significa que acesso universal significativo — não apenas acesso formal — depende de política pública deliberada, financiamento público e regulação que corrija os incentivos de mercado. A tecnologia existe; o que falta é vontade política de usá-la onde o mercado não vai por conta própria.

17. Quais são os desafios da computação sustentável e seu impacto socioambiental?

Computação sustentável não é um nicho de pesquisa — é uma necessidade estrutural que a escala atual do setor tornou urgente. As TIC respondem por aproximadamente 5% a 6% do consumo global de energia elétrica. Data centers sozinhos consumiram 460 TWh em 2022 — cerca de 2% da demanda global — com projeções de dobrar até 2026, um crescimento equivalente a adicionar ao sistema elétrico mundial uma demanda da ordem da Alemanha. O principal motor desse crescimento é IA: treinar modelos de linguagem de grande escala, executar inferência em bilhões de consultas diárias, manter a infraestrutura que suporta tudo isso. Para o Brasil, que pode ser incapaz de expandir geração e distribuição de energia na velocidade que esse crescimento demandaria, isso não é problema abstrato — é restrição concreta à soberania tecnológica.

O problema estrutural é que energia nunca foi tratada como critério de projeto. Desempenho, custo e confiabilidade são variáveis explícitas em qualquer processo de desenvolvimento de software ou hardware. Energia não é. Desenvolvedores escolhem algoritmos por complexidade computacional, não por consumo energético. Infraestrutura é dimensionada por capacidade de processamento, não por eficiência por operação. Benchmarks comparam velocidade, não joules por resultado. Mudar isso exige não apenas novas métricas e ferramentas, mas uma mudança de cultura dentro da comunidade de computação que ainda não ocorreu — e que não ocorrerá por inércia.

A tensão mais importante nesse contexto é entre eficiência e escala. Ganhos de eficiência energética têm sido consistentes nas últimas décadas — processadores fazem mais operações por watt, data centers operam com PUE muito menor. Mas o paradoxo de Jevons se aplica aqui com força: computação mais barata por operação significa mais operações realizadas. O consumo total cresce porque a demanda cresce mais rápido do que a eficiência melhora. Isso não invalida investimento em eficiência — sem ele, o crescimento seria ainda mais insustentável — mas significa que eficiência sozinha não resolve o problema. Algum instrumento precisa atuar sobre a demanda, não apenas sobre a eficiência da oferta.

No plano técnico, os eixos de atuação são múltiplos. Do lado algorítmico, técnicas como quantização, destilação de modelos e poda reduzem custo computacional de inferência com perda de desempenho geralmente aceitável — um modelo destilado que usa 10% da energia do modelo original com 95% do desempenho é frequentemente a escolha correta, mas raramente é a escolha padrão porque o critério de comparação é desempenho, não eficiência. Do lado de software, compiladores e sistemas de execução que otimizam para consumo energético além de velocidade existem em estado incipiente — Green Software Foundation e iniciativas similares estão construindo a infraestrutura técnica, mas adoção ainda é marginal. Do lado de hardware, aceleradores especializados oferecem ganhos de eficiência para cargas específicas que CPUs de propósito geral não alcançam, mas concentram poder em poucos fabricantes e criam dependência tecnológica.

HPC é o caso onde a mudança cultural é mais visível e mais lenta. Sistemas de alto desempenho são historicamente ranqueados pelo Top500, que mede velocidade pura em petaflops. O Green500, que ranqueia por eficiência energética em gigaflops por watt, existe desde 2007 e ainda é tratado como lista secundária. Redefinir o que significa alto desempenho para incluir eficiência energética como critério de primeira classe — não como restrição a ser satisfeita depois de maximizar velocidade — é tanto um desafio técnico quanto político dentro de uma comunidade que construiu sua identidade em torno de recordes de velocidade.

O impacto socioambiental tem dimensões que vão além do consumo energético. Fabricação de semicondutores usa minerais raros com cadeias de suprimento problemáticas e processe que consomem água em escala industrial. Resfriamento de data centers usa água em quantidade que cria conflito com outros usos em regiões com estresse hídrico. Lixo eletrônico cresce mais rápido do que qualquer outra categoria de resíduo, com taxas de reciclagem formal ainda baixas. O ciclo de vida completo dos sistemas computacionais tem pegada ambiental muito maior do que o consumo energético durante a operação sugere.

17.1. Como enfrentar os desafios da computação sustentável?

Enfrentar os desafios da computação sustentável exige atuar em camadas que têm lógicas diferentes: técnica, formativa, regulatória e de governança. Nenhuma delas resolve o problema sozinha, e a mais urgente não é necessariamente a mais desenvolvida. O paradoxo central é que as ferramentas técnicas para reduzir impacto ambiental da computação existem e são conhecidas — o que falta é que energia seja tratada como critério de projeto com o mesmo peso que desempenho e custo.

No plano algorítmico, a resposta mais imediata é tornar eficiência energética mensurável e comparável. Métricas como energia por inferência, emissões por treinamento e consumo por operação precisam se tornar padrão em avaliações de modelos e sistemas — não métricas opcionais reportadas quando conveniente. Iniciativas como ML CO2 Impact e CodeCarbon oferecem ferramentas para medir pegada de carbono de treinamento de modelos, mas adoção ainda é voluntária e marginal. Exigir reporte de eficiência energética em submissões de artigos e competições — como o Green500 faz para HPC — criaria incentivos para que a comunidade pesquise e otimize o que mede. Técnicas de compressão de modelos — quantização, destilação, poda — precisam ser avaliadas não apenas por preservação de desempenho, mas por redução de custo energético, e essa avaliação precisa ser parte do processo padrão de desenvolvimento.

No plano de software e infraestrutura, compiladores e runtimes que otimizam para eficiência energética além de velocidade são a peça mais subdesenvolvida. Frameworks de ML como TensorFlow e PyTorch otimizam para throughput em GPU; otimização conjunta de throughput e consumo energético é área de pesquisa ativa mas sem adoção em produção. Escalonamento dinâmico de recursos — reduzir capacidade provisionada quando demanda é baixa, em vez de manter infraestrutura ociosa — é tecnicamente maduro mas culturalmente subadotado: provisionar em excesso é mais fácil do que calibrar. Data centers que usam resfriamento líquido direto, localização em climas frios ou próximos a fontes de energia renovável abundante, e acordos de compra de energia que garantem adicionalidade — não apenas compensação via créditos — reduzem impacto operacional de forma concreta.

No plano formativo, a lacuna é dupla e o documento da SBC é explícito sobre isso. Muitos desenvolvedores não conhecem os fundamentos do consumo energético em sistemas computacionais — não por falta de interesse, mas porque isso nunca foi parte do currículo. Muitos professores também não conhecem, o que torna a reforma curricular dependente de atualização docente antes de reforma de conteúdo. Introduzir consumo energético como tema transversal em disciplinas de algoritmos, sistemas operacionais, arquitetura de computadores e desenvolvimento de software é mais eficaz do que criar uma disciplina isolada de computação sustentável que fica na periferia do currículo.

No plano regulatório, a resposta mais estrutural é tornar o custo ambiental da computação visível e vinculante. Relatórios obrigatórios de emissões para operadores de data centers acima de certo porte — como o EU Energy Efficiency Directive começa a exigir na Europa — criam transparência e base para regulação posterior. Inclusão de critérios de eficiência energética em processos de procurement público de tecnologia — que representa parcela significativa da demanda total — cria incentivos de mercado para que fornecedores otimizem para eficiência. O documento da SBC recomenda explicitamente incluir redução de impacto ambiental da computação em iniciativas de governança ESG no setor produtivo — o que traduz a agenda de sustentabilidade para a linguagem que o mercado de capitais já está aprendendo a falar.

Para o Brasil especificamente, a matriz elétrica com alta participação de renováveis é vantagem comparativa concreta que ainda não foi estrategicamente aproveitada para atrair infraestrutura computacional sustentável. Data centers alimentados predominantemente por hidrelétricas, eólica e solar têm pegada de carbono operacional muito menor do que os mesmos data centers em países com matriz fóssil — e essa diferença deveria ser mensurável, certificável e comunicável como diferencial competitivo. O desafio é garantir que crescimento de infraestrutura computacional no Brasil seja atendido por expansão de renováveis, não por acionamento de termelétricas na margem — o que exige coordenação entre política energética e política de desenvolvimento tecnológico que ainda não existe de forma explícita.

A constatação mais incômoda é que as ferramentas técnicas existem e as respostas institucionais são conhecidas. O obstáculo é cultural e de incentivos: uma comunidade que construiu sua identidade em torno de recordes de desempenho precisa incorporar eficiência energética como critério de excelência, não como restrição. Isso não acontece por convicção individual — acontece quando métricas, financiamento, reconhecimento e regulação se alinham para tornar sustentabilidade a escolha de menor resistência.

18. Quais são os desafios para a formação de recursos humanos em computação no Brasil?

Formação de recursos humanos é o único dos temas identificados pela SBC que não é um Grande Desafio entre os seis — é condição de viabilidade para todos eles simultaneamente. Sem profissionais qualificados em IA responsável, os sistemas serão desenvolvidos sem as salvaguardas necessárias. Sem especialistas em cibersegurança, infraestruturas críticas permanecem vulneráveis. Sem pesquisadores em computação quântica, o Brasil assiste de fora a uma transição tecnológica com implicações diretas para soberania. A lógica se repete em cada desafio: o gargalo não é a tecnologia — é a capacidade humana de desenvolvê-la, implantá-la e governá-la adequadamente.

O problema quantitativo é concreto e documentado. Em cibersegurança, o déficit estimado de profissionais especializados no Brasil em 2024 estava entre 140 e 750 mil — uma faixa tão ampla que já revela a dificuldade de medir o que não existe. Em IA, a demanda cresce mais rápido do que qualquer programa de formação consegue acompanhar, e a competição com mercados internacionais drena talentos antes que se tornem pesquisadores ou docentes. Em computação quântica, a formação requer perfil que integra física quântica, matemática avançada e ciência da computação — combinação que currículos tradicionais de nenhuma dessas áreas produz sozinha. O déficit não é apenas de engenheiros e desenvolvedores; é de pesquisadores capazes de produzir conhecimento próprio, e de docentes capazes de transmiti-lo.

O problema qualitativo é mais difícil de medir e mais difícil de resolver. Os perfis que os Grandes Desafios demandam não são variações do perfil técnico tradicional — são perfis que combinam competência técnica com capacidade de transitar entre disciplinas, compreender impacto social, tomar decisões éticas sob incerteza e colaborar com áreas que têm linguagens e métodos completamente diferentes. Profissionais de IA responsável precisam conversar com juristas e filósofos. Profissionais de cibersegurança precisam entender comportamento humano tanto quanto criptografia. Profissionais de computação sustentável precisam saber o que é um watt tanto quanto o que é um algoritmo. Esses perfis não emergem de currículos que adicionam uma disciplina de ética no último semestre de um curso técnico.

A velocidade dos avanços tecnológicos tornou o modelo de formação baseado em graduação estática estruturalmente inadequado. Um currículo aprovado hoje e implementado em dois anos forma profissionais para um mercado que existia há quatro anos. Isso não é problema de gestão universitária — é consequência de ciclos de inovação que a estrutura institucional de ensino superior não foi projetada para acompanhar. A resposta não é reformar currículos mais frequentemente; é construir capacidade de formação continuada que opere em paralelo com a graduação, ao longo de toda a trajetória profissional. Parcerias entre universidades e setor produtivo para formação continuada, microcredenciais em áreas emergentes e programas de atualização docente são respostas estruturais, não complementos opcionais.

A atualização docente é frequentemente o gargalo anterior à reforma curricular — e o documento da SBC é explícito sobre isso. Em computação sustentável, muitos professores não estão familiarizados com fundamentos de consumo energético em sistemas computacionais; reformar o currículo sem antes formar o docente produz disciplinas ensinadas por profissionais que aprendem o conteúdo junto com os alunos. Em IA responsável, ética e impacto social ensinados por quem nunca interagiu com as comunidades afetadas pelos sistemas que projeta tendem a ser abstratos e ineficazes. Formação de formadores é passo anterior à formação de profissionais, e é sistematicamente negligenciada.

A competição com o mercado é o problema mais concreto e menos discutido. Salários que a indústria paga para os mesmos perfis que a academia precisa reter como pesquisadores e docentes são incompatíveis com a carreira acadêmica em praticamente todas as áreas de computação de alta demanda. Isso cria seleção adversa: os profissionais com maior empregabilidade no mercado são exatamente os que têm menos incentivo para permanecer na academia. Bolsas de pós-graduação que representam fração pequena de um salário de mercado não competem. Sem resolver essa equação — por alguma combinação de melhores remunerações, benefícios não financeiros da carreira acadêmica

e criação de trajetórias híbridas entre academia e indústria — qualquer política de formação de recursos humanos em computação enfrenta um vazamento estrutural.

A infraestrutura limita o que é possível aprender. Computação quântica não se aprende sem acesso a equipamento quântico ou simuladores de qualidade. Segurança não se aprende sem ambientes de laboratório onde ataques podem ser simulados com segurança. IA de grande escala não se aprende sem acesso a infraestrutura de GPU que universidades brasileiras raramente têm em quantidade suficiente. A ausência de infraestrutura adequada não apenas limita a qualidade da formação prática — limita a pesquisa que os docentes conseguem fazer, o que por sua vez limita a qualidade do que ensinam. Investimento em infraestrutura de pesquisa e ensino não é custo de manutenção; é condição de qualidade.

18.1. Como enfrentar os desafios para a formação de recursos humanos em computação no Brasil?

Enfrentar os desafios de formação de recursos humanos em computação no Brasil exige aceitar que não há solução única — o problema é simultaneamente quantitativo, qualitativo, institucional e econômico, e cada dimensão exige respostas distintas. A tentação de tratar tudo como problema curricular — adicionar disciplinas, reformar matrizes, criar cursos novos — subestima a profundidade do problema e superestima o que reforma curricular consegue resolver sozinha.

Para o déficit quantitativo, especialmente em cibersegurança, a resposta de curto prazo é formação acelerada e certificação profissional em paralelo com a graduação tradicional. Bootcamps intensivos, microcredenciais em áreas específicas e programas de requalificação para profissionais de áreas adjacentes produzem resultados em meses, não em anos. Não substituem formação profunda — mas aliviam um déficit que a graduação tradicional não consegue cobrir na velocidade necessária. Para médio e longo prazo, criação de cursos de especialização e pós-graduação focados nas áreas de maior déficit, com bolsas que tornem a formação financeiramente viável para quem já está no mercado, é a resposta estrutural.

Para o problema qualitativo de perfis interdisciplinares, a reforma mais eficaz não é criar uma disciplina de cada coisa faltante — é redesenhar como projetos e avaliações funcionam. Projetos multidisciplinares obrigatórios que exigem colaboração entre estudantes de computação, ciências sociais, direito e saúde produzem aprendizado que nenhuma disciplina isolada produz. Avaliações que incluem dimensões de impacto social, ética e sustentabilidade junto com correção técnica sinalizam o que a formação considera importante. Programas de extensão que colocam estudantes em contato com comunidades afetadas por tecnologia criam o tipo de experiência que torna abstrações concretas. Nenhuma dessas mudanças requer aprovação de um novo currículo completo — podem ser implementadas dentro da estrutura existente por docentes dispostos a mudar como ensinam.

Para atualização docente, a resposta é investimento específico e contínuo, não eventual. Programas de sabbatical em empresas de tecnologia, parcerias com centros de pesquisa internacionais para imersão em temas emergentes, e comunidades de prática entre docentes que estão aprendendo os mesmos temas são respostas estruturais. O modelo de atualização docente baseado em participação esporádica em conferências é insuficiente para a velocidade dos avanços em IA, computação quântica e cibersegurança. Agências de fomento que financiam pesquisa mas não financiam sistematicamente atualização docente estão otimizando para o produto errado.

Para competição com o mercado, não há solução que não envolva ou melhorar remuneração ou criar benefícios que o mercado não oferece. Remuneração de docentes e pesquisadores em computação é decidida por estruturas de carreira pública que mudam lentamente. O que é mais rápido de implementar é criar trajetórias híbridas: vínculos que permitem ao pesquisador dividir tempo entre academia e empresa sem perder direitos de carreira em nenhum dos dois lados, propriedade intelectual compartilhada que torna a pesquisa acadêmica financeiramente interessante para o pesquisador, e bolsas de produtividade que reconhecem o custo de oportunidade de permanecer na academia. Algumas universidades brasileiras já experimentam modelos nessa direção; generalizá-los exige mudança regulatória que vai além do que uma universidade pode fazer sozinha.

Para infraestrutura, a resposta mais eficiente é compartilhamento. Nenhuma universidade brasileira tem recursos para manter infraestrutura de ponta em todas as áreas de computação simultaneamente. Centros de computação compartilhados — como o LNCC para HPC — que atendem múltiplas instituições são mais eficientes do que cada universidade tentar ter tudo. Para computação quântica, onde o custo de equipamento é proibitivo, acesso via nuvem quântica — IBM Quantum, Google Quantum AI, IonQ — já é realidade e permite formação prática sem equipamento físico local. Acordos de acesso preferencial para pesquisa e ensino com provedores de infraestrutura em nuvem são negociáveis e têm custo muito menor do que infraestrutura própria.

Para soberania tecnológica na formação, o documento da SBC aponta o que é mais estratégico: fomentar pesquisa aplicada a problemas brasileiros, não apenas adaptar soluções desenvolvidas no exterior. Isso exige que agências de fomento priorizem explicitamente projetos que produzem conhecimento sobre realidade brasileira — dados em português, modelos para contextos brasileiros, soluções para desigualdades brasileiras. E exige que universidades valorizem esse tipo de pesquisa nos critérios de progressão de carreira, em vez de tratar publicação internacional como único critério de excelência.

O que atravessa todas essas respostas é uma constatação que nenhuma política isolada resolve: formar recursos humanos em computação no Brasil em quantidade e qualidade suficientes para os Grandes Desafios da próxima década exige um esforço coordenado entre governo, universidades, agências de fomento, setor produtivo e sociedade civil que ainda não existe de forma articulada. Cada ator age dentro de seus incentivos e restrições, e os incentivos de nenhum deles estão perfeitamente alinhados com o objetivo coletivo. Criar essa coordenação é o desafio mais difícil — e o mais necessário.