

## Sumário da Aula

1. 3.6 Busca Informada (Heurística): motivação e definições
2. 3.5.4 Lowest-Cost-First (Uniform-Cost) Search [ponte para A\*]
3. Heuristic Depth-First e Greedy Best-First
4. 3.6.1 Busca A\*
5. 3.6.2 Branch and Bound
6. 3.6.3 Construção de Heurísticas

## 1 Busca Informada: Motivação

As estratégias não informadas (BFS, DFS, UCS) não consideram diretamente quão perto um estado está da meta. A **busca informada** utiliza uma **função heurística**  $h(n) \geq 0$  que estima o custo do melhor caminho de  $n$  até a meta.

### Definições

$h$  é **admissível** se  $h(n) \leq h^*(n)$ , onde  $h^*(n)$  é o custo real mínimo de  $n$  à meta. Quanto melhor a qualidade de  $h$ , mais a busca é guiada para regiões promissoras do espaço.

**Derivação de heurísticas (ideia):** resolver um *problema simplificado* e usar seu custo como estimativa (linha reta em rotas; Manhattan no 8-puzzle; bancos de padrões etc.).

## 2 3.5.4 Lowest-Cost-First (Uniform-Cost) Search

Em muitos domínios, os arcos têm **custos não unitários** e o objetivo é **minimizar o custo total** do caminho até a meta. A **lowest-cost-first search** (ou **uniform-cost search**, UCS) expande sempre o caminho de **menor custo acumulado**  $g(p)$  na fronteira.

### Ideia e Implementação

- Trate a **fronteira** como uma **fila de prioridade** ordenada por  $g(p)$ .
- Ao expandir, gere sucessores com seus custos atualizados e reinsira na fronteira.
- Quebra de empates pode seguir ordem FIFO, menor profundidade, ou mesmo menor  $h$  (se disponível) apenas como *desempate* — não altera a otimalidade de UCS.

```
import heapq

class Node:
    __slots__ = ("state", "parent", "action", "g", "depth")
    def __init__(self, state, parent=None, action=None, g=0.0):
        self.state = state
        self.parent = parent
        self.action = action
        self.g = g
        self.depth = 0 if parent is None else parent.depth + 1

def solution(n):
    path = []
    while n and n.parent is not None:
        path.append(n.action)
        n = n.parent
    return list(reversed(path))

def uniform_cost_search(s0, is_goal, successors):
    """Retorna a sequência de ações de menor custo (se existir)."""
    start = Node(s0, None, None, g=0.0)
    frontier = [(0.0, id(start), start)] # (g, tie, node)
    best_g = {} # melhor custo por estado

    while frontier:
        g, _, node = heapq.heappop(frontier)
        if is_goal(node.state):
            return solution(node)
        # poda por custo já conhecido
```

```

    if node.state in best_g and best_g[node.state] <= g:
        continue
    best_g[node.state] = g
    for (a, s_next, cost) in successors(node.state):
        g_next = g + float(cost) # custos de arco > 0
        child = Node(s_next, node, a, g_next)
        heapq.heappush(frontier, (g_next, id(child), child))
    return None

```

## Corretude e Condições Suficientes

Se (i) o fator de ramificação é finito e (ii) todos os custos de arco são **estritamente positivos** ( $\geq \epsilon > 0$ ), então a UCS é **completa** e **ótima**. O *primeiro* caminho-meta removido da fronteira tem o menor custo.

**Nota (paradoxo de Zeno):** sem limite inferior  $\epsilon$ , pode haver caminhos infinitos de custo finito e a busca não terminar.

## Complexidade (pior caso)

Se  $c$  é o custo da solução ótima e  $k = c/\epsilon$ , a busca pode gerar até  $O(b^k)$  caminhos de comprimento  $\leq k$ , resultando em **tempo** e **espaço**  $O(kb^k)$ .

**Ponte para  $A^*$**  UCS é um caso particular de  $A^*$  quando  $h(n) \equiv 0$ , logo  $f(n) = g(n)$ . Essa visão unifica UCS e  $A^*$  sob a mesma política de fila de prioridade.

## 3 Heuristic Depth-First e Greedy Best-First

### Heuristic Depth-First Search

Ordena vizinhos por  $h(n)$ , expandindo o mais promissor primeiro. Não garante completude nem otimalidade.

### Greedy Best-First Search

Seleciona sempre o nó com menor  $h(n)$  na fronteira ( $f(n) = h(n)$ ). Pode ser rápido, mas é míope e pode ciclar.

```

def greedy_best_first_search(s0, is_goal, successors, h):
    from heapq import heappush, heappop
    frontier = []
    heappush(frontier, (h(s0), Node(s0)))
    explored = set()
    while frontier:
        _, node = heappop(frontier)
        if is_goal(node.state):
            return solution(node)
        explored.add(node.state)
        for (a, s_next, cost) in successors(node.state):
            if s_next not in explored:
                heappush(frontier, (h(s_next), Node(s_next, node, a)))
    return None

```

## 4 Busca $A^*$

A  $A^*$  usa  $f(n) = g(n) + h(n)$ , combinando custo acumulado e heurística. Se  $h$  é admissível e os custos de arco são  $\geq \epsilon > 0$ ,  $A^*$  é **completa** e **ótima**.

```

def a_star_search(s0, is_goal, successors, h):
    import heapq
    start = Node(s0, None, None, 0.0)
    frontier = [(h(s0), id(start), start)]
    best_g = {}
    while frontier:
        f, _, node = heapq.heappop(frontier)
        if is_goal(node.state):
            return solution(node)
        if node.state in best_g and best_g[node.state] <= node.g:
            continue
        best_g[node.state] = node.g
        for (a, s_next, cost) in successors(node.state):
            g_next = node.g + float(cost)
            heapq.heappush(frontier, (g_next + h(s_next),
                                     id(node) ^ hash(s_next),
                                     Node(s_next, node, a, g_next)))
    return None

```

**Intuição:**

$$\text{start} \xrightarrow{g(n)} n \xrightarrow{h(n)} \text{goal} \Rightarrow f(n) = g(n) + h(n).$$

**Admissibilidade (esboço):** Com  $b < \infty$ , custos  $\geq \epsilon > 0$  e  $h$  admissível, a primeira solução retornada por  $A^*$  é ótima.

## 5 Branch and Bound

Combina **DFS** com um **limite (bound)**: poda caminhos com  $g(n) + h(n)$  não menor que o melhor custo encontrado. Gera soluções cada vez melhores e retorna a ótima no final; economiza memória comparado a expandir em largura.

## 6 Construção de Heurísticas

Heurísticas admissíveis via *problema simplificado*:

- Rotas: distância em linha reta (Euclidiana).
- 8-puzzle: peças fora do lugar; soma de distâncias Manhattan.
- Entrega de pacotes: maior distância necessária entre coletas/destinos.

**Pattern Databases:** pré-compute soluções de subproblemas e armazene para consultas rápidas de  $h$ .

## 7 Resumo Comparativo

Método	Usa $g(n)$	Usa $h(n)$	Completo	Ótimo	Observações
UCS (Lowest-Cost-First)	Sim	Não	Sim ( $\epsilon > 0$ )	Sim	Caso especial de $A^*$ com $h \equiv 0$ .
Greedy Best-First	Não	Sim	Não	Não	Rápido, mas míope; pode ciclar.
$A^*$	Sim	Sim	Sim	Sim (se $h$ admissível)	Equilíbrio entre custo real e estimado.
Branch and Bound	Sim	Opcional	Sim	Sim	DFS + poda por bound; economiza memória.

Tabela 1: Comparação entre métodos (assumindo custos de arco  $\geq \epsilon > 0$  e ramificação finita).

## Mini-Exercícios

1. Mostre por que UCS é um caso particular de  $A^*$ .
2. Dê um exemplo em que BFS encontra o menor número de passos, mas UCS encontra um caminho de *menor custo*.
3. Modele um grafo pequeno e registre a fronteira a cada passo para UCS e  $A^*$  com  $h$  admissível.
4. Projete uma heurística admissível para o 8-puzzle e compare  $A^*$  com UCS.
5. Implemente branch and bound e compare com  $A^*$  no mesmo problema.

## Leitura Recomendada

- Poole & Mackworth, Seção 3.5.4 (UCS) e Seção 3.6 (Busca Informada).
- Seção 3.6.3: *Designing a Heuristic Function*.