

Lista de Exercícios Regressão Logística

1. Considere o conjunto de dados abaixo, com duas variáveis explicativas e uma variável resposta binária:

i	x_{1i}	x_{2i}	y_i
1	0	0	0
2	1	0	0
3	0	1	0
4	1	1	1

Considere o modelo com intercepto:

$$p_i = \mathbb{P}(y_i = 1 \mid \mathbf{x}_i) = \sigma(\mathbf{w}^\top \tilde{\mathbf{x}}_i), \quad \sigma(z) = \frac{1}{1 + e^{-z}},$$

onde $\tilde{\mathbf{x}}_i = (1, x_{1i}, x_{2i})^\top$.

- (a) Monte a matriz X (com coluna de 1's) e o vetor \mathbf{y} .
 (b) Escreva a função custo (log-verossimilhança negativa):

$$J(\mathbf{w}) = - \sum_{i=1}^n \left(y_i \log p_i + (1 - y_i) \log(1 - p_i) \right).$$

- (c) Mostre que o gradiente de $J(\mathbf{w})$ pode ser escrito como

$$\nabla J(\mathbf{w}) = X^\top (\mathbf{p} - \mathbf{y}),$$

onde $\mathbf{p} = (p_1, \dots, p_n)^\top$.

- (d) Considere $\mathbf{w}^{(0)} = \mathbf{0}$. Calcule explicitamente os valores p_i , o gradiente $\nabla J(\mathbf{w}^{(0)})$ e o custo $J(\mathbf{w}^{(0)})$.
 (e) Execute **duas iterações manuais** de descida do gradiente:

$$\mathbf{w}^{(t+1)} = \mathbf{w}^{(t)} - \alpha \nabla J(\mathbf{w}^{(t)}),$$

usando passo de aprendizado $\alpha = 0.5$.

- (f) Para cada iteração, calcule $J(\mathbf{w}^{(t)})$ e verifique se o custo diminui.
2. Considere agora o conjunto de dados

$$(x_1, x_2, y) \in \{(0, 0, 0), (2, 0, 0), (0, 2, 0), (2, 2, 1)\}.$$

- (a) Repita os itens (a)–(f) da questão anterior, usando o mesmo passo α .
 (b) Compare o comportamento da descida do gradiente nos dois conjuntos de dados.
 (c) Explique a influência da escala das variáveis explicativas na convergência do método.
3. Formule o ajuste da regressão logística como um problema de otimização irrestrita. Explique por que a solução não admite forma fechada, ao contrário do caso de mínimos quadrados.
4. Mostre que a Hessiana da função custo pode ser escrita como

$$\nabla^2 J(\mathbf{w}) = X^\top W X, \quad W = \text{diag}(p_i(1 - p_i)).$$

- (a) Mostre que W é semidefinida positiva.
 (b) Conclua que $J(\mathbf{w})$ é uma função convexa.
 (c) Explique a consequência dessa propriedade para a convergência da descida do gradiente.
5. Sob quais condições a solução do problema de regressão logística é única? Discuta o papel do posto da matriz X e do comportamento dos termos $p_i(1 - p_i)$.
6. Explique o conceito de separação perfeita em regressão logística. Mostre, conceitualmente, por que nesse caso a função custo não possui minimizador finito. Relacione esse fenômeno com o comportamento da descida do gradiente.
7. Considere o problema regularizado:

$$\min_{\mathbf{w}} J(\mathbf{w}) + \frac{\lambda}{2} \|\mathbf{w}\|^2.$$

- (a) Derive o gradiente da função custo regularizada.
 (b) Explique como a regularização afeta a convergência da descida do gradiente.
 (c) Discuta o papel da regularização na presença de separação perfeita.
8. Mostre que

$$\log \frac{p(\mathbf{x})}{1 - p(\mathbf{x})} = \mathbf{w}^\top \tilde{\mathbf{x}}.$$

Explique a interpretação dos coeficientes do modelo em termos de:

- (a) log-odds;
 - (b) odds ratio.
9. Defina o vetor $\mathbf{r} = \mathbf{y} - \mathbf{p}$.
- (a) Mostre como \mathbf{r} aparece na expressão do gradiente.
 - (b) Compare a interpretação desse resíduo com o resíduo da regressão linear por mínimos quadrados.
 - (c) Explique por que não existe, no caso logístico, uma interpretação direta em termos de projeção ortogonal.